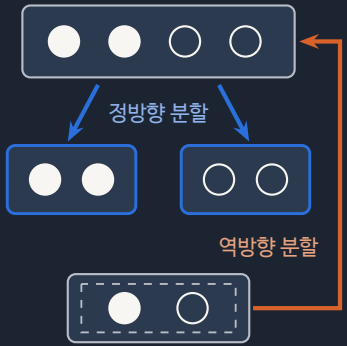
ASWISS

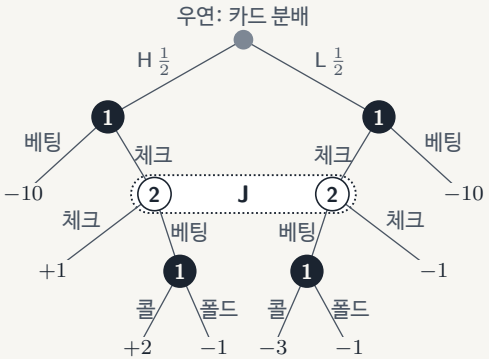
Abstraction Split WIth Sampling by Strategy

학습한 전략의 후회로
추상화를 스스로 나누는 방법



졸업 논문 연구 · 2인 영합 불완전 정보 게임의 적응형 추상화 · 2026년 11월

불완전 정보 게임과 정보집합



플레이어 2는 카드를 모른다:

두 상태가 하나의 정보집합 J

게임 트리 · 카드 분배(우연)와 두 플레이어의 행동. 끝의 수는 플레이어 1의 보수(칩)

보는 것 / 못 보는 것 · 플레이어 1(●)은 자기 카드를 본다. 플레이어 2(○)는 행동만 본다

정보집합 (information set) · 그 플레이어가 서로 구별할 수 없는 상태들의 묶음

전략 (strategy) · 정보집합마다 행동 확률 하나. J의 두 상태에서는 같은 확률로 둔다

내시 균형 (Nash equilibrium) · 누구도 혼자 전략을 바꿔 이득을 볼 수 없는 상태

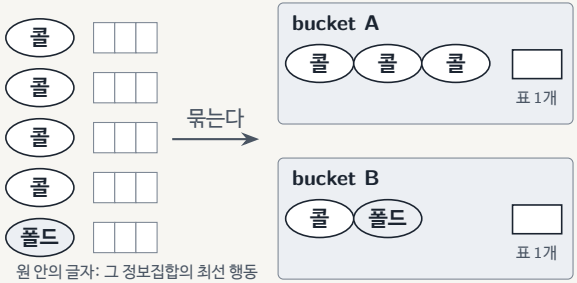
exploitability · 상대가 내 전략을 알고 최선으로 대응할 때 균형보다 더 잃는 양. 0이면 균형

정의는 일반 이론의 보충 설명이다.

추상화: 묶으면 얻는 것과 잃는 것

큰 게임은 정보집합이 너무 많다. 세븐 포커에서는 같은 정보집합이 학습 중 거의 다시 나오지 않아 정보집합마다 표를 둘 수 없다.

정보집합마다 표



원 안의 글자: 그 정보집합의 최선 행동

✓ 이득

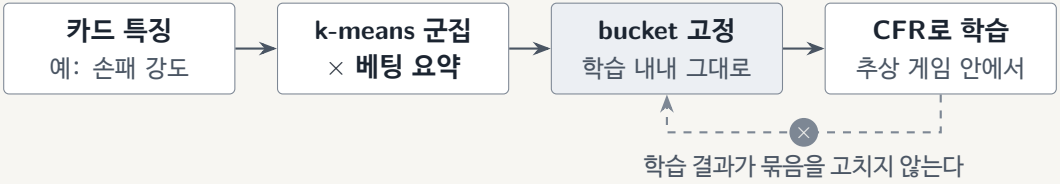
표 3개가 1개. 한 곳에서 배운 것을 나머지가 함께 쓴다.

! 손실

둘 다 콜이거나 둘 다 폴드. 한쪽은 최선이 아닌 행동을 한다.

추상화 (abstraction): 정보집합을 bucket으로 묶는 분할. bucket 안의 정보집합은 한 전략을 함께 쓴다. 무엇을 묶느냐가 성능을 정한다.

고정 추상화에 빠져 있는 것



❶ 묶는 기준이 해를 보지 않는다

무엇을 합쳐도 되는지는 게임의 해(균형)가 정한다. 카드 특징은 그것을 모른다.

❷ 전략적 동등성의 보장이 없다

같은 bucket이 같은 행동을 원한다는 보장이 없다. 다르면 앞 장의 손실이 생긴다.

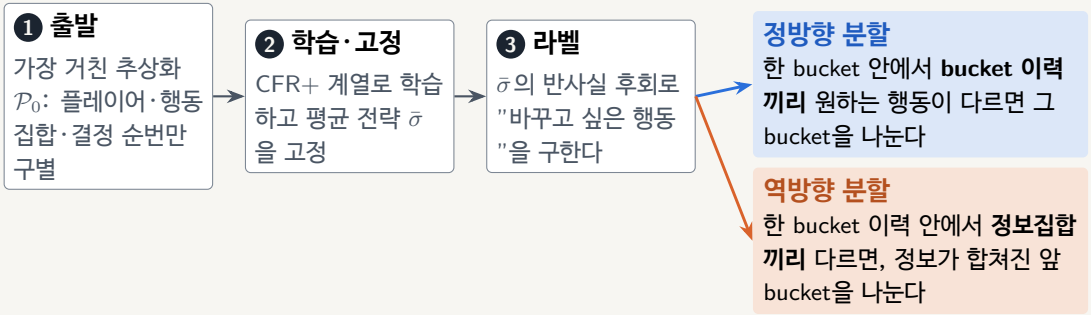
❸ 손실을 찾아 고칠 길이 없다

"여기는 다르게 두고 싶다"는 신호가 나와도 추상화는 바뀌지 않는다.

보충: 고정 추상화에서 학습기가 노리는 것은 추상 게임의 해다. 그것이 원 게임의 균형이라는 보장은 따로 없다.

ASWISS의 핵심 아이디어

ASWISS는 미리 정한 특징이 아니라 **학습된 전략의 반사실 후회**를 이용하여 정보집합의 분할 필요성을 판단하고, **정방향** 및 **역방향** **분할**로 추상화에 의해 숨겨진 전략적 차이를 복원하려는 방법이다.



다시 학습하고 판정한다. 아무것도 나뉘지 않으면 멈춘다 (**정지 상태**). 다음 장부터 후회 → 자료구조 → 예시 게임 순서로 한 단계씩 본다.

후회: 그 행동을 했더라면 얼마나 나았을까

예시 게임의 결정 2 (체크 → 상대 베팅 → 콜 또는 폴드). 지금 전략은 "항상 콜"이다.

카드	콜의 값	폴드의 값	폴드의 후회	$\times\frac{1}{2}$
H	$+2$	-1	$-1-(+2)=-3$	$\mathbf{-1.5}$
L	-3	-1	$-1-(-3)=+\mathbf{2}$	$\mathbf{+1.0}$

후회 (regret) = 그 행동의 값 − 지금 전략의 값.
양수면 "바꾸고 싶다".

$\times\frac{1}{2}$ = 상대와 우연이 여기로 데려올 확률 (카드 $\frac{1}{2}$ × 상대 베팅 1). 남의 확률만 곱하므로 **반사실 (counterfactual)** 값이라 한다.

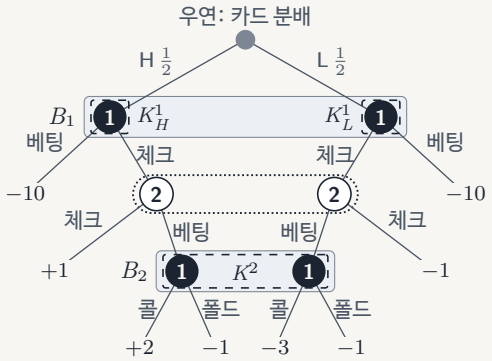
CFR: 후회를 줄여 가는 반복

1. 지금 전략 σ^t로 끝까지 계산
2. 정보집합·행동마다 반사실 후회를 누적
3. 누적 후회가 양수인 행동을 그 비율로 둔다 (regret matching)
4. **반복한 전략들의 평균 $\bar{\sigma}$이 균형으로 간다**

보충 · 왜 평균인가: 지금 전략은 서로 쫓고 쫓기며 진동할 수 있다. 2인 영합·완전 기억 게임에서는 평균의 수렴이 보장된다.

$r(I,a)=q(I,a)-\sum_b \sigma(I,b)\,q(I,b)$, $\quad q(I,a)=\sum_{h\in I}\pi_{-i}(h)\cdot(h$에서 a를 둔 뒤의 기대 보수$)$

bucket과 bucket 이력



출발점 $\mathcal{P}_0$: (플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로 묶는 가장 거친 분할

1 **정보집합** I · 게임이 정한 구별 단위 (여기서는 플레이어 1의 결정점 하나하나)

bucket B · 전략을 함께 쓰는 정보집합 묶음 = 추상 게임의 정보집합

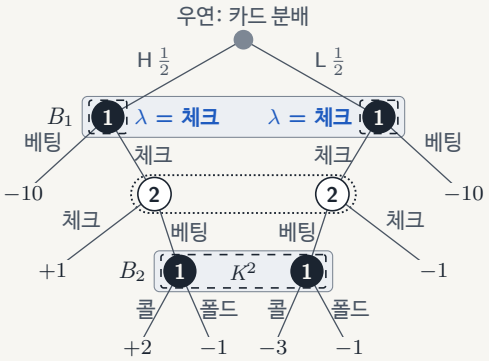
bucket 이력 K · (지나온 bucket, 둔 행동, 새 관측). 과거는 bucket 번호로만 기억한다

$\bar{\sigma}$ · bucket마다 하나인 평균 전략 (판정 때 고정)

$\lambda(K)$ · K에 모은 후회가 가장 큰 행동 = **라벨**

B_1에는 이력이 둘: $K^1_H =$ (카드 H), $K^1_L =$ (카드 L)
B_2에는 이력이 하나: $K^2 =$ (B_1, 체크, 상대 베팅)
→ 카드는 B_1에 합쳐져 B_2에서는 H와 L이 구별되지 않는다

정방향 분할: 이력끼리 라벨이 갈리면 나눈다

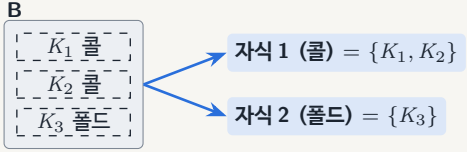


B_1 의 두 이력 모두 "체크" → 유지 (옳다)

규칙 · 한 bucket 안의 이력들이 공통 라벨을 하나도 갖지 않으면 라벨별로 자식 bucket을 만든다.

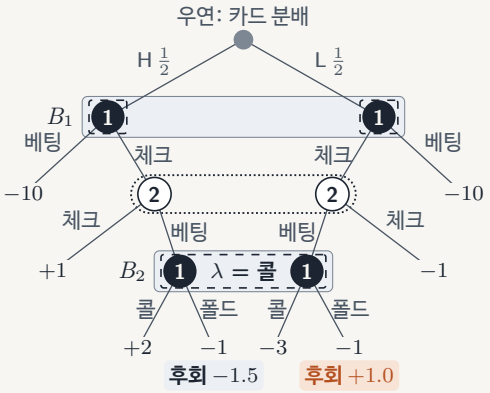
라벨이 갈리는 경우 (설명용 예시 값)

이력	폴드	콜	레이즈	라벨
K_1	-0.40	$+0.70$	$+0.10$	콜
K_2	-0.20	$+0.35$	-0.05	콜
K_3	$+0.55$	-0.30	-0.60	폴드

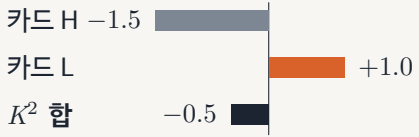


같은 이력은 갈라지지 않는다 · 자식은 표를 새로 시작한다

정방향 분할만으로는 멈출 수 있다 (명제 H4)



결정 2에서 폴드의 반사실 후회 (앞의 표)



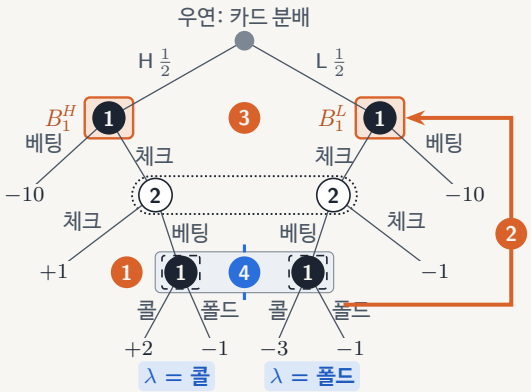
L은 폴드를 원하지만 ($+1.0$) 같은 이력의 H와 더해져 사라진다. 라벨은 "콜"이고 B_2에는 이력이 하나뿐이라 나눌 것이 없다 → **정지**

그런데 L이 폴드로 바꾸면 1을 더 얻는다
→ **NashConv = 1**

NashConv = 각 플레이어가 혼자 바꿔 얻을 수 있는 이득의 합

Leduc: 정방향만 (+ 트리 유지)은 $\mathcal{P}_0$에서 한 번도 못 나누고 2.93에 머물렀다.

역방향 분할: 정보가 합쳐진 앞 bucket을 나눈다



1 진단

이력 K^2 안의 정보집합끼리 라벨이 갈린다: H는 콜, L은 폴드 ($H_K > 0$)

2 거슬러 오르기

이력이 달랐는데 같은 bucket에 묶인 앞 결정 → 결정 1의 B_1 (보조정리 H3)

3 역방향 분할

B_1을 B_1^H, B_1^L로 나눈다. 정보집합은 그대로 두고, 뒤 결정의 이력이 갈라진다

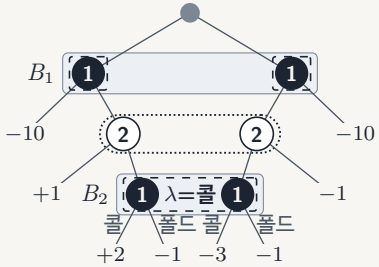
4 다음 판정

결정 2의 이력이 둘로 갈라져, 정방향 분할이 B_2를 콜과 폴드로 나눈다

7-stud 구현은 정보집합이 반복되지 않아, 직전 결정의 bucket 이력으로 묶어 진단한다 (교차 검정). 부록 A5.

같은 게임, 두 결과: 정방향만 vs 역방향 포함

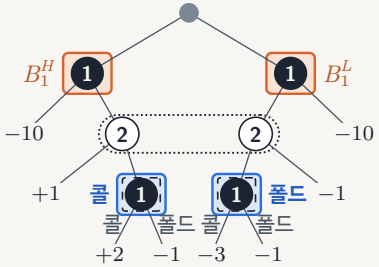
정방향만



정지 · NashConv = 1

L의 폴드 선호가 H와 상쇄되어 보이지 않는다

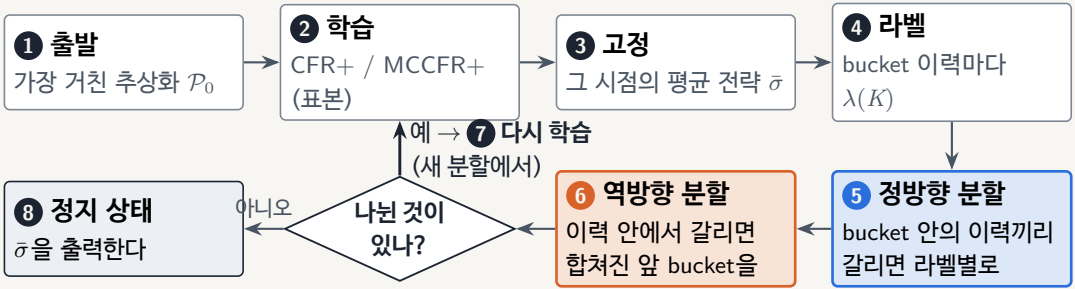
정방향 + 역방향



균형 · 원 게임 값 0 (H 콜, L 폴드, 상대 체크)

판정 두 번: 역방향(B_1) → 정방향(B_2)

알고리즘 흐름



주의: 정지 상태는 "더 나눌 곳을 찾지 못한 상태"이지, 그 자체로 원 게임의 내시 균형이 아니다. 균형이 되려면 학습기가 bucket 후회를 ε 아래로 만들어야 한다 (정리 H5).

실험에서는 판정 문턱 없이 epoch마다 (반복 수 두 배 간격) 판정했다.

의사코드와 정의

$\mathcal{P} \leftarrow \mathcal{P}_0$
repeat
  $\bar{\sigma} \leftarrow \text{Learn}(\mathcal{P})$ ▷ CFR+ / MCCFR+
  for each bucket 이력 K:
    $\lambda(K) \leftarrow \arg\max_a r^{\bar{\sigma}}(K, a)$ 또는 없음
  정방향: 이력들이 공통 라벨을 갖지 않는 bucket을 라벨별로 나눈다
  역방향: 멤버의 라벨이 갈리는 K마다 정보가 합쳐진 지점의 bucket을 나눈다
until 아무것도 나뉘지 않음
return $\bar{\sigma}$

$\mathcal{P}_0$
(플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로

Learn
이론: $\rho_{\mathcal{P}} \le \varepsilon$를 만드는 학습기로 가정한다.
실험: 문턱 없이 epoch마다 판정

라벨 $\lambda(K)$
분할 시점의 $\bar{\sigma}$을 고정하고 그 아래 순간 반사실 후회 $r^{\bar{\sigma}}(K, a) = \sum_{I \in K} r^{\bar{\sigma}}(I, a)$가 가장 큰 행동. 모두 0 이하면 "없음"

정지 상태
아무것도 나뉘지 않은 판정: 모든 $G_B = 0$이고 모든 $H_K = 0$

인증 부등식: 세 항이 각각 무엇을 막는가

정리 H1 (어떤 lifting된 전략 σ에도 성립)

$$\mathrm{NashConv}(\sigma) \;\le\; \rho_{\mathcal{P}}(\sigma) \;+\; \sum_B G_B \;+\; \sum_K H_K$$

bucket 후회 $\rho_{\mathcal{P}}$
bucket이 스스로 느끼는 후회의 합
→ **학습기 (CFR+)가 줄인다**

bucket 안 상쇄 G_B
한 bucket 안에서 서로 다른 이력끼리 상쇄되어 사라진 후회
→ **정방향 분할이 0으로**

이력 안 상쇄 H_K
한 이력 안에서 정보집합끼리 상쇄되어 사라진 후회
→ **역방향 분할이 0으로**

정지 상태 ($G = 0$, $H = 0$)에서는 $\mathrm{NashConv} \le \rho_{\mathcal{P}}$. 학습기가 $\rho_{\mathcal{P}} \le \varepsilon$를 주면 $\mathrm{NashConv} \le \varepsilon$ (정리 H5, 조건부). 표본 라벨이면 인증에 $+4\sum_K \eta_K$ (정리 H6).

예시 게임 (명제 H4의 정지점)
$H_{K^2} = \max(0, -1.5) + \max(0, +1.0) - \max(0, -0.5) = 1 = \mathrm{NashConv}$
→ 남은 것은 전부 이력 안 상쇄였다

무엇이 증명되었고, 무엇이 조건부인가

증명 · 부등식

H1 인증: $\mathrm{NashConv} \le \rho_{\mathcal{P}} + \sum G_B + \sum H_K$ · **H6 표본 판정**: 좋은 사건 위에서 거짓 분할이 없고 인증에 $+4\sum_K \eta_K$

증명 · 유한 종료

H2: 분할은 많아야 $N - |\mathcal{P}_0|$번 ($N=$ 정보집합 수). 라벨이 추정이어도 같다

증명 · 반례와 동치

H4: 정방향만으로 NashConv $= 1$에서 멈추는 게임이 있다 · **H7**: 모든 bucket의 부모(직전 bucket, 행동)가 하나 $\Leftrightarrow$ 추상화의 완전 기억

조건부 정리

H5: 학습기가 $\rho_{\mathcal{P}} \le \varepsilon$를 주고 라벨이 정확하면, 정방향 + 역방향은 $\mathrm{NashConv} \le \varepsilon$에서 멈춘다

실험적 수렴

Leduc 21/21 정지 상태, mini-stud $\varepsilon = 0.2$에서 정지 상태 도달, Kuhn 수렴. 관찰한 설정에서만 말할 수 있다 (증명 아님)

미해결

학습기 조건: CFR 평균은 자기가 가지 않는 곳의 후회 때문에 $\rho_{\mathcal{P}} \le \varepsilon$를 맞추지 못한다 (추상화 없는 Leduc도 $\rho/2 = 0.0855$에서 멈춤) · 표본 역방향 분할의 보장

명칭은 증명 초안(ASWISS_HISTORY_PROOF_KO.md)을 따른다. 정확한 가정과 진술은 부록 A2–A6.

실험 설계: 다섯 가지 질문

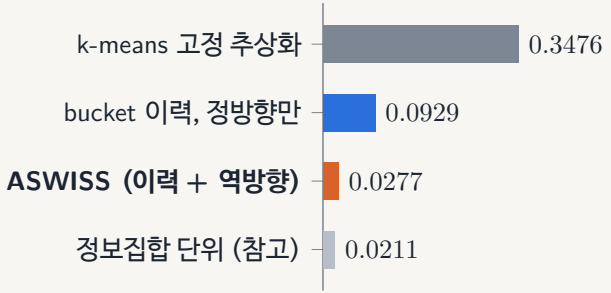
	연구 질문	게임 (크기)	지표
A	역방향 분할이 bucket 이력 단위의 손실을 되찾는가?	mini-stud (정보집합 51,114)	exploitability (정확)
B	어떤 출발점에서도 정지 상태에 도달하는가?	Leduc (288), Kuhn	exploitability (정확)
C	트리 구조(완전 기억)는 무엇을 돕는가?	Leduc, 고정 추상화 96 bucket	$D/2$, exploitability
D	큰 게임에서 고정 추상화(k-means)와 비교하면?	7-stud 헤즈업 (5구부터)	LBR (근사 하한)
E	판정 문턱 ε가 도움이 되는가?	7-stud 5.11M roots	LBR (근사 하한)

exploitability (정확)
원 게임에서 최선 대응에 잃는 양 ($=$ NashConv / 2). 0이면 균형. 게임 트리 전체를 계산할 수 있는 작은 게임에서만 잴 수 있다.

LBR (local best response)
큰 게임용 근사. 최선 대응을 일부만 찾으므로 exploitability의 **하한**이다. 실제 값은 더 클 수 있다. 낮을수록 좋다.

A. mini-stud: 역방향 분할이 손실을 되찾았다

질문 A · 역방향 분할이 bucket 이력 단위의 손실을 되찾는가?



정보집합 51,114개 · 4,096만 반복 · seed 3개 평균 · 평균 정책의 정확한 exploitability (낮을수록 좋음) · 비교군마다 bucket 수가 다르다 (부록 A8)

3.4배

역방향 분할을 더하자 0.0929 → 0.0277

정지 상태 도달

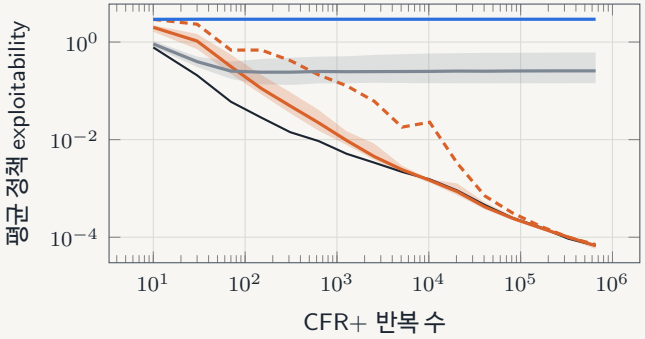
$\varepsilon = 0.2$ 비교군: 2,900만–3,050만 반복에 $G = 0$, $H = 0$. 실제 0.034–0.038 $\leq$ 인증 0.19–0.20

0.0211

정보집합 단위 라벨이 조금 더 낮지만, 큰 게임에서는 정보집합이 반복되지 않아 쓸 수 없다

B. Leduc: 어떤 출발점에서도 정지 상태에 도달

질문 B · 가장 거친 분할이든 무작위 추상화든, 정지 상태와 낮은 exploitability에 도달하는가?



추상화 없는 CFR+
ASWISS, 무작위 출발 20개 (중앙값)
ASWISS, 가장 거친 $\mathcal{P}_0$ 에서
같은 bucket 수의 k-means (중앙값)
정방향만 + 트리 유지, $\mathcal{P}_0$ 에서

21 / 21

$\mathcal{P}_0$와 무작위 출발 20개 모두 정지 상태 ($G = 0$, $H = 0$)

0.000067

65.5만 반복 뒤. 추상화 없는 CFR+와 같다

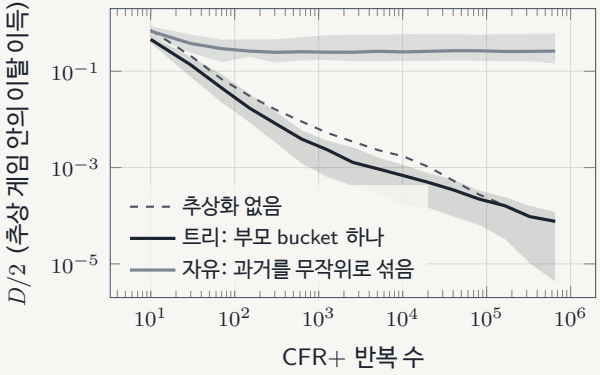
203–270

최종 bucket (288개 중). 같은 수의 k-means는 0.14–0.88

정확한 CFR+ · 정보집합 288 · 띠: 무작위 출발 20개 (및 짝지은 k-means)의 최소–최대 · 두 축 모두 로그 · 이 설정에서 관찰한 결과이며 수렴의 증명은 아니다

C. 트리 구조와 역방향 분할의 역할

질문 C · 트리 구조(각 bucket의 부모가 하나 = 완전 기억)는 무엇을 돕고, 무엇을 돕지 않는가?



D = bucket 하나만 바꿔 얻는 이득의 합 (0이면 추상 게임을 푼 것) · Leduc, 고정 무작위 추상화 96 bucket, seed 10개 · 띠: 최소–최대

65.5만 반복	트리	자유
$D/2$ (추상 게임)	**0.00008**	0.26
exploitability (원 게임)	1.81	1.74

학습기: 트리면 CFR+가 추상 게임을 푼다 ($D \to 0$). 자유 추상화는 멈춘다.

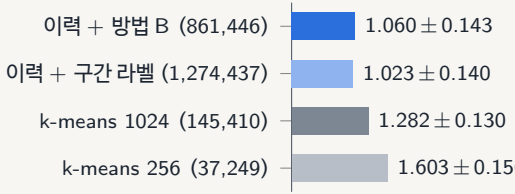
원 게임: 그래도 트리가 낫지 않았다 (1.81 대 1.74). 추상 게임 성능 $\neq$ 원 게임 성능.

분할의 수렴: 정방향만 + 트리 유지는 $\mathcal{P}_0$에서 2.93에 멈췄다. 역방향이 있으면 트리 여부와 상관없이 21/21 정지 상태.

D. 7-stud: 부분 구현과 완성형 시범을 나눠 본다

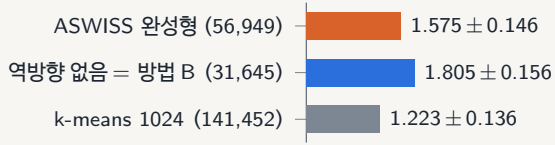
질문 D · 실제 크기의 게임에서 고정 추상화(k-means)와 비교하면?

100M roots · 역방향 없는 부분 구현



방법 B − k-means 1024 = $-\mathbf{0.22}$
$[-0.41, -0.04]$ (같은 deal로 짝지은 차이)

5.11M roots · ASWISS 완성형 시범

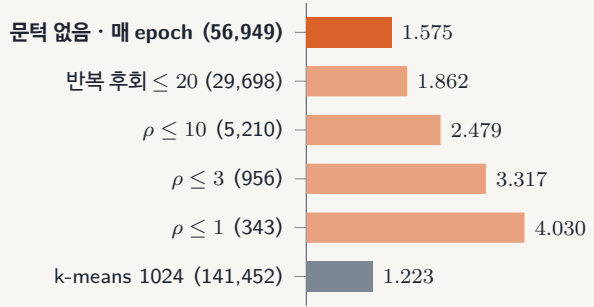


역방향 효과 $-\mathbf{0.23} \pm \mathbf{0.21}$. 그러나 k-means 1024보다 아직 $+\mathbf{0.35} \pm \mathbf{0.19}$ 높다. 완성형 100M은 미실행

평균 정책 LBR (낮을수록 좋음, ± 95% 구간) · 괄호: bucket 수 · **LBR은 exploitability의 근사 하한이다** · PolicyLBR 64 particles, 20,000 pair, seed 1 · 설정은 부록 A7 · **두 패널은 학습량·bucket 수·버전이 달라 서로 비교하지 않는다**

E. 판정 문턱: 엄격할수록 나빠졌다

질문 E · 학습기 조건을 흉내 내어, 후회가 작아질 때까지 판정을 미루면 좋아지는가?



7-stud 5.11M roots · 평균 정책 LBR, 20,000 pair (낮을수록 좋음) · 괄호: 마지막 bucket 수

엄격할수록 나빴다

문턱을 기다린 비교군은 모두 매 epoch 판정보다 LBR이 높았다. 기다리는 동안 bucket이 수십–수백 개에 묶여 있었다.

후회가 작다 $\neq$ 정책이 좋다

$\varepsilon = 1$은 bucket 36개, $\rho = 0.86$에서 통과했지만 LBR은 7.5로 같은 시점 k-means의 7.6배였다.

문턱의 뜻

이론에서 ε는 학습기 조건($\rho_{\mathcal{P}} \leq \varepsilon$)이지 성능 지표가 아니다. 실험에서는 매 epoch 판정했다.

검증된 것과 아직 아닌 것

확인된 것

✓ **증명** · 인증 부등식 (H1), 유한 종료 (H2), 정방향만의 반례 (H4), 표본 판정 (H6), 트리 ⇔ 완전 기억 (H7)

✓ **Kuhn · Leduc** · $\mathcal{P}_0$와 무작위 출발 모두 정지 상태, 추상화 없는 CFR+와 같은 값 (관찰)

✓ **mini-stud** · 역방향 분할로 0.0929 → 0.0277 (seed 3개)

✓ **7-stud 100M** · 역방향 없는 bucket 이력 (방법 B)이 k-means 1024보다 LBR 0.22 낮음 (seed 1)

아직 아닌 것

! **원 게임 보장** · H5의 학습기 조건을 CFR 평균이 만족한다는 증명이 없다

! **완성형의 큰 게임 성능** · 5.11M에서 k-means 1024보다 +0.35 높다. 100M은 미실행

! **표본 역방향 분할** · 7-stud는 직전 결정의 이력으로 묶는 약한 판정. 일반 보장 없음

! **평가의 한계** · LBR은 근사 하한, seed 1개, 4구 버림 · 공개 휴리스틱

! **문턱과 절차** · 이론의 학습기 조건 ($\rho_{\mathcal{P}} \le \varepsilon$)과 실험 절차 (매 epoch 판정)가 다르다

정리와 다음 단계

학습된 전략의 반사실 후회로 나눌 곳을 정하고, **정방향**(bucket 안)과 **역방향**(이력 안) 분할로 추상화가 숨긴 전략적 차이를 되살린다.

요약

- 작은 게임: 어떤 출발점에서도 정지 상태, 추상화 없는 CFR+와 같은 값
- 큰 게임: bucket 이력은 고정 k-means를 넘었다 (역방향 없는 100M). 완성형은 시범 단계
- 이론: 인증과 종료는 증명. 원 게임 균형은 학습기 조건 아래에서만

다음 단계

1. 7-stud에서 역방향 분할을 넣은 ASWISS의 100M 실행
2. 카드 휴리스틱(power 군집) 제거: 카드를 한 장씩 관측으로
3. 학습기 조건을 경로 밖 후회 없이 다시 쓰기 (도달 가중 이득 D)
4. 표본 학습기 MCCFR+의 수렴 보장

A1. 기호와 정의

반사실 가치 $q^\sigma(I,a) = \sum_{h\in I} \pi^\sigma_{-i}(h) \sum_{z \sqsupseteq ha} \pi^\sigma(ha,z)\, u_i(z)$

순간 후회 $r^\sigma(I,a) = q^\sigma(I,a) - \sum_b \sigma(I,b)\, q^\sigma(I,b), \quad r^\sigma(I,\varnothing) = 0$ ("없음")

모은 후회 $r(K) = \sum_{I\in K} r(I), \quad r(B) = \sum_{K\subseteq B} r(K)$

ψ와 라벨 집합 $\psi(x) = \max(0, \max_a x_a), \quad M(x) = \arg\max_{\ell \in A\cup\{\varnothing\}} x_\ell$. B가 일치: $\bigcap_{K\subseteq B} M(r(K)) \neq \emptyset$

세 양 $\rho_{\mathcal{P}}(\sigma) = \sum_B \psi(r(B))$, $G_B = \sum_{K\subseteq B} \psi(r(K)) - \psi(r(B))$, $H_K = \sum_{I\in K} \psi(r(I)) - \psi(r(K))$ (ψ가 준선형이라 $G, H \geq 0$)

bucket 이력 $\kappa_{\mathcal{P}}(I) = \big(i, A(I), b(I^1), a^1, \ldots, b(I^m), a^m, o(I)\big)$. 7-stud 구현은 직전 bucket만: $(b(I^m), a^m, o(I))$

허용 분할 모든 bucket이 이력류(같은 bucket 이력의 정보집합 묶음)의 합집합. $\mathcal{P}_0$: (플레이어, 행동집합, 자기 결정 순번)으로 묶음

NashConv $\sum_i \big(\max_{\sigma_i'} u_i(\sigma_i', \sigma_{-i}) - u_i(\sigma)\big)$. 실험의 exploitability = NashConv / 2

출처: 증명 초안 ASWISS_HISTORY_PROOF_KO.md §2. G는 완전 기억 유한 2인 영합 전개형 게임, σ는 lifting된 행동 전략($\sigma(I) = \sigma(b(I))$).

A2. 정리 H1 (인증)과 정리 H2 (유한 종료)

보조정리 H5 (NashConv 분해) · β_i를 σ_{-i}에 대한 순수 최선 응답이라 하면

$$\mathrm{NashConv}(\sigma) = \sum_i \sum_{I \in \mathcal{I}_i} \pi_i^{\beta_i}(I)\, r^{\sigma}(I, \beta_i(I)) \le \sum_I \psi(r^{\sigma}(I)).$$

보조정리 H6 (두 단계 라벨 항등식) · 허용 분할과 임의의 σ에 대해

$$\sum_I \psi(r(I)) = \rho_{\mathcal{P}}(\sigma) + \sum_B G_B + \sum_K H_K, \qquad G_B = 0 \Leftrightarrow B\text{가 일치}, \quad H_K = 0 \Leftrightarrow \bigcap_{I \in K} M(r(I)) \neq \emptyset.$$

정리 H1 (인증) · 임의의 허용 분할과 lifting된 σ에 대해
$\mathrm{NashConv}(\sigma) \le \rho_{\mathcal{P}}(\sigma) + \sum_B G_B + \sum_K H_K$. 모든 bucket이 일치하면
$\mathrm{NashConv}(\sigma) \le \rho_{\mathcal{P}}(\sigma) + \sum_K H_K$.

정리 H2 (유한 종료) · 분할(역방향 포함)은 모든 표본 경로에서 많아야 $N - |\mathcal{P}_0|$번이다. 증명: 분할마다 bucket 수가 엄격히 늘고, bucket 수는 N을 넘지 못한다. 라벨이 정확한지와 무관하다.

출처: 증명 초안 §5. H1은 H5와 H6을 잇는 것으로 증명된다. 상태: [증명].

A3. 조건부 결과와 학습기 조건

ε-오라클 가정 · 매 라운드 학습기가 $\rho_{\mathcal{P}}(\bar{\sigma}) \le \varepsilon$인 lifting된 프로필을 낸다. 라벨은 정확히 계산한다.

정리 H3 (역방향 없이) · 이 가정 아래 분할 라운드는 많아야 $N - |\mathcal{P}_0|$번이고, 멈춘 출력은 $\mathrm{NashConv} \le \varepsilon + \sum_K H_K$. 모든 $H_K = 0$이면 $\mathrm{NashConv} \le \varepsilon$.

정리 H5 (정방향 + 역방향) · 같은 가정 아래, 멈춘 출력은 $\mathrm{NashConv} \le \varepsilon$. $\varepsilon = 0$이면 원 게임의 정확한 균형.
증명: 멈춤 = 정방향 분할 없음($G_B = 0$) + 역방향 분할 없음($H_K = 0$). 정리 H1에 넣는다.

오라클이 낼 프로필의 존재 · $\mathcal{P}_0$에서 나뉜 분할은 같은 bucket의 두 정보집합이 한 경로 위에 있지 않으므로 $\rho_{\mathcal{P}} = 0$인 프로필이 있다. 그러나 $H_K = 0$까지 함께 만족한다는 뜻은 아니다 (명제 H4).

학습기 조건 [미해결] · 표준 CFR 평균은 이 가정을 만족하지 않는다. 자기가 가지 않는 정보집합의 평균 전략이 거의 고쳐지지 않아 그곳의 후회가 남는다. 추상화 없는 Leduc에서도 CFR+ 평균의 $\rho/2$가 0.0855에서 멈췄다 (그때 exploitability 0.000067).

출처: 증명 초안 §6, §8, §11과 원본 슬라이드의 이론 표. 정리 H3은 원본 슬라이드에는 없고 증명 초안에만 있다.

A4. 합쳐진 지점, 역방향 규칙, 트리 구조

보조정리 H3 (정보가 합쳐진 지점) · $I \neq I'$ 이고 $\kappa(I) = \kappa(I')$ 이면 어떤 $j \leq m$에서

$$I^j \neq I'^j, \qquad \kappa(I^j) \neq \kappa(I'^j), \qquad b(I^j) = b(I'^j).$$

즉 j번째 결정에서 이력은 달랐는데 같은 bucket에 들어갔다.

역방향 분할 규칙 · 이력류 K의 멤버들이 최대 라벨을 공유하지 않으면 ($H_K > 0$) 대표 라벨이 다른 두 멤버 I, I'을 고르고, 지점 j의 bucket $b(I^j)$에서 $\kappa(I^j)$를 떼어 자식 하나로 만든다. 그다음 라운드부터 I와 I'의 이력이 달라진다 (보조정리 H1).

구현 (mini-stud · Leduc): 쌍은 첫 멤버와 라벨이 다른 멤버, 지점은 이력이 다른 가장 가까운 앞 결정.
역방향으로만 나뉜 자식은 부모의 표를 복사한다.

보조정리 H7 (트리 = 추상화의 완전 기억) · $\mathcal{P}$가 $\mathcal{P}_0$를 세분할 때, 모든 bucket의 멤버가 같은 (직전 자기 bucket, 행동)을 가지는 것과 같은 자기 과거 열 전체를 가지는 것은 동치다. 이때 CFR(+)는 추상 게임을 푼다. 그래도 정방향만으로는 멈출 수 있다 (명제 H4의 게임도 트리다).

출처: 증명 초안 §4, §8. 직전 bucket만 쓰는 bucket 이력 (7-stud)에서도 H3은 $j_1 = \max\{j : \kappa(I^j) \neq \kappa(I'^j)\}$로 성립한다.

A5. 표본 판정 (정리 H6)과 구현의 차이

설정 · 라운드 k에서 $\bar{\sigma}$을 고정하고, 두 좌석 모두 $\bar{\sigma}$로 두는 외부 샘플링 순회를 n_k번 한다. 순회마다 방문한 정보집합의 표본 후회를 이력별로 더해 n_k로 나눈 것이 $\hat{r}(K)$.

집중 · 한 순회에서 이력류 K의 멤버는 많아야 하나 방문되므로 $\hat{r}(K)$는 불편 추정량이다. 확률 $1-\delta$ 이상에서 모든 k, K, a에 대해

$$|\hat{r}(K,a) - r^{\bar{\sigma}}(K,a)| \le \eta_K^{(k)} = \Delta_K \sqrt{\frac{2}{n_k} \ln \frac{\pi^2 N_A(k+1)^2}{3\delta}}.$$

정리 H6 · 여유 라벨(최대에서 2η 이내)로 판정하면, 좋은 사건 위에서 (1) 참으로 일치하는 bucket은 나뉘지 않고 (2) 나뉠 때 각 이력은 참 최대 라벨과 4η 이내인 자식으로 가며 (3) 분할 없는 라운드의 출력은 $\mathrm{NashConv} \le \rho_{\mathcal{P}} + 4\sum_K \eta_K + \sum_K H_K$ (4) 분할 수는 많아야 $N - |\mathcal{P}_0|$.

7-stud 구현과의 차이 · 순회 수에 상한(epoch당 256만 roots)이 있어 η가 0으로 가지 않는다. 여유 라벨 대신 $z=2$ 정규 근사 검정을 써서 거짓 분할이 있을 수 있다(종료는 깨지지 않지만 bucket이 는다). 역방향은 정보집합 대신 직전 결정의 이력으로 묶고, 두 세부 이력이 서로 자기 라벨을 유의하게 선호할 때만 나눈다(교차 검정). 일반 보장은 [미해결].

출처: 증명 초안 §9, §8과 원본 슬라이드의 역방향 설명. 상태: H6 [증명], 표본 역방향 [미해결].

A6. 명제 H4 게임의 계산

위치	계산 (σ^*: 플레이어 1은 체크 후 콜, 플레이어 2는 베팅)	결론
결정 1, 카드 H	베팅의 후회 $\frac{1}{2}(-10-2)=-6$	라벨 {체크, 없음}
결정 1, 카드 L	베팅의 후회 $\frac{1}{2}(-10+3)=-3.5$	라벨 {체크, 없음} $\to B_1$ 일치
결정 2, 카드 H	폴드의 후회 $\frac{1}{2}(-1-2)=-1.5$	
결정 2, 카드 L	폴드의 후회 $\frac{1}{2}(-1+3)=+1.0$	
결정 2, 이력 K^2	합 -0.5	라벨 {콜, 없음} $\to$ 나뉘지 않음
플레이어 2 (J)	베팅으로 0.5를 더 얻는다	후회 없음
결과	$\rho_{\mathcal{P}}(\sigma^*)=0$, 모든 bucket 일치, $\mathrm{NashConv}(\sigma^*)=1=H_{K^2}$	정방향만으로는 정지
원 게임 균형	H 콜, L 폴드, 플레이어 2 체크. 플레이어 1의 값 0 (σ^*에서는 -0.5)	역방향 $\to$ 정방향 두 판정 뒤 도달

출처: 증명 초안 §7–§8. 덜 극단적인 경우(베팅 보상 -1)에는 L의 첫 결정에서 베팅이 나아 B_1이 정방향으로 나뉘고 문제가 저절로 풀린다.

A7. 실험 설정

	mini-stud	Kuhn · Leduc	7-stud
게임	정보집합 51,114	Leduc 정보집합 288 (rank만)	헤즈업, 5구부터 학습
학습기	MCCFR+ (외부 샘플링), 라벨은 정확 계산	정확한 전체 트리 CFR+	MCCFR+ (외부 샘플링), 라벨은 표본
학습량	4,096만 반복	65만 5,350반복	100M roots / 5.11M roots
seed	3	$\mathcal{P}_0$ + 무작위 출발 20 (Leduc)	1
판정	epoch마다 (두 배 간격)	epoch마다	epoch마다, 라벨 표본 상한
지표	평균 정책 exploitability	평균 정책 exploitability, $D/2$	평균 정책 LBR (64 particles, 20,000 pair)
비교군	k-means 고정, 정보집합 단위, 이력 정방향만	같은 bucket 수의 k-means, 정방향만 + 트리 유지	k-means 256 / 1024, 방법 B, 구간 라벨

출처: 원본 슬라이드와 aswiss/README_KO.md, aswiss/small/README_KO.md, aswiss/stud7/README_KO.md. 4구 버림·공개는 휴리스틱(power 군집).

A8. 비교 조건의 차이 (같은 조건의 비교가 아닌 것)

mini-stud 비교군 (4,096만 반복)	bucket 수 (seed 1/2/3)
정보집합 단위, 매 epoch	12,683 / 12,839 / 12,888
bucket 이력, 정방향만	12,895 / 13,132 / 13,158
bucket 이력 + 역방향 (ASWISS)	15,745 / 16,304 / 15,811
카드 k-means 고정	7,051

mini-stud의 대가: 역방향 분할 뒤 $H_K = 0$이 되었을 때 bucket 이력이 정보집합의 99.4–99.8%를 구별했다. 이 게임에서 $H_K = 0$을 얻으려면 이력이 사실상 정보집합을 다 기억해야 했다. 큰 게임에서도 그런지는 미해결.

7-stud에서 다른 것

- 100M과 5.11M은 학습량과 버전(역방향 유무)이 다르다
- 같은 패널 안에서도 bucket 수가 다르다 (예: 86만 대 14.5만)
- 5.11M에서는 k-means 256도 측정했지만 여기서는 더 강한 k-means 1024만 보였다

맞춘 것

같은 deal, LBR seed, 64 particles, 20,000 pair로 평가했고 평균 정책끼리 비교했다

비율 (원본 값으로 계산)

100M 방법 B / k-means 1024 = 0.83

5.11M 완성형 / k-means 1024 = 1.29

A9. 판정 문턱 실험의 세부

mini-stud (정확 계산, 1만 반복마다 검사)

- $\varepsilon = 0.2$ + 역방향: 29–30.5M에 "문턱 통과 + 모든 bucket 일치 + $H_K = 0$" 판정 (세 seed). 인증 $\rho/2$ = 0.19–0.20, 실제 NashConv/2 = 0.034–0.038
- 역방향이 없으면 같은 상태에서 $H_K/2 \approx 0.40$이 남아 인증 0.59–0.60, 실제 값도 두 배
- CFR 평균은 계속 바뀌므로 학습을 이어 가면 라벨이 다시 갈려 분할이 이어졌다
- $\varepsilon = 0.05$, 0.1은 4천만 반복 동안 판정이 5–8번뿐. $\varepsilon/\sqrt{t}$ 문턱은 고정 분할에서 ρ도 $t^{-1/2}$로 줄어 추상화를 얼린다

7-stud (표본, 5.11M roots, seed 1)

- $\varepsilon = 1$: bucket 36개, $\hat{\rho} = 0.86$에서 통과했지만 LBR 7.5 (같은 시점 k-means 1024의 7.6배)
- 자식이 많이 생기면 ρ가 크게 뛴다 (149 → 956 bucket 판정 직후 2.40 → 54.0)
- 학습 순회의 표본 후회 합은 오라클 조건을 대신하지 못한다

출처: 원본 슬라이드($\varepsilon = 1$, 정지 상태 도달)와 증명 초안 §6. 원본 PDF에 없던 수: 0.40, 0.59–0.60, 5–8번, 2.40 → 54.0.

A10. 원본 이후 작업 (참고): 라벨용 혼합 평균

원본 PDF에 없는 내용이다. 발표 본문에서는 쓰지 않았다.

문제 · 평균 전략은 자기가 거의 가지 않게 된 곳에서 초반 값에 멈춘다. 정책에는 영향이 없지만 (실현 계획의 질량이 0), 자주 가는 정보집합의 라벨이 그 아래의 멈춘 값으로 계산되어 "그 행동이 사실 더 좋다"는 분할 신호를 놓친다.

규칙 (`--avg-fill plain`) · 판정에 쓰는 전략만 바꾼다. 평균 전략으로 자기 도달확률이 10^{-4} 이상인 곳은 평균 전략, 그보다 작은 곳은 그 bucket의 현재 전략들의 단순 평균. 내놓는 정책은 그대로다.

지금까지의 결과 · 명제 B4(a) 반례: 평균 전략만으로는 끝까지 안 나뉘었고 (NashConv 1), 혼합 평균으로는 150반복에 나뉘어 0으로 수렴. Leduc 21개 출발점: 정책과 bucket 수는 그대로, 판정에 쓴 평균의 $\rho_{\mathcal{P}}/2$가 0.090 $\rightarrow$ 0.00029. mini-stud: **차이 없음** (0.0277 $\rightarrow$ 0.0271).

한계 · 이력 안 상쇄 (명제 H4)는 풀지 못한다. 문턱 10^{-4} 한 값만 시험했다. 증명은 없다. 7-stud 100M 비교 (hist_bbf 대 hist_bb)는 진행 중이다.

출처: aswiss/AVG_FILL_KO.md. 필요 없으면 이 장은 지워도 본문에 영향이 없다.