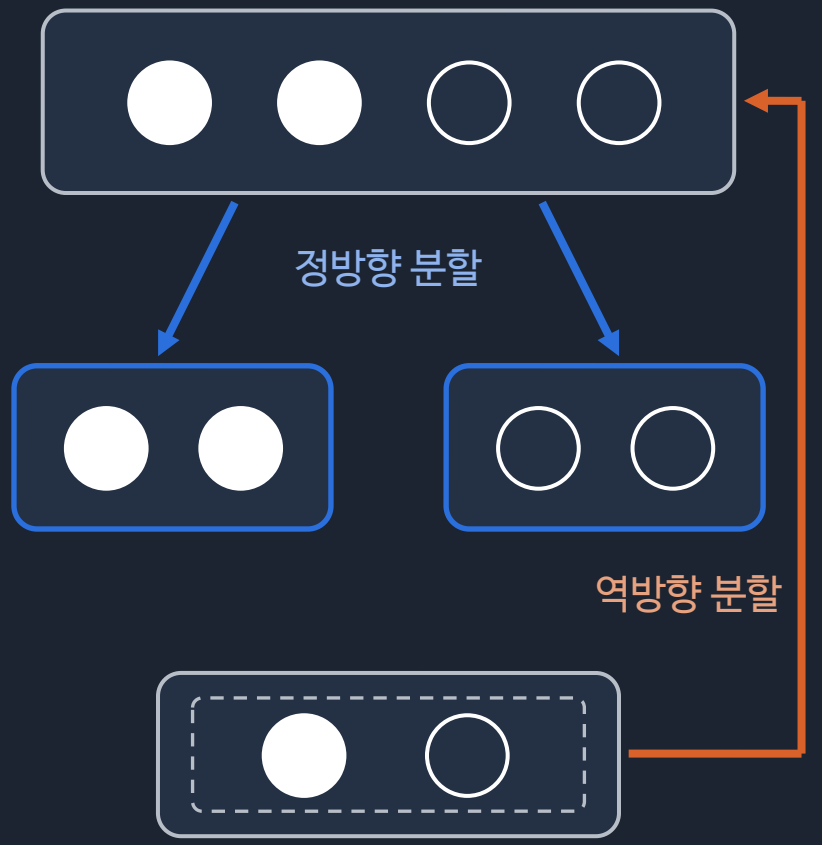
ASWISS

Abstraction Split WIth Sampling by Strategy

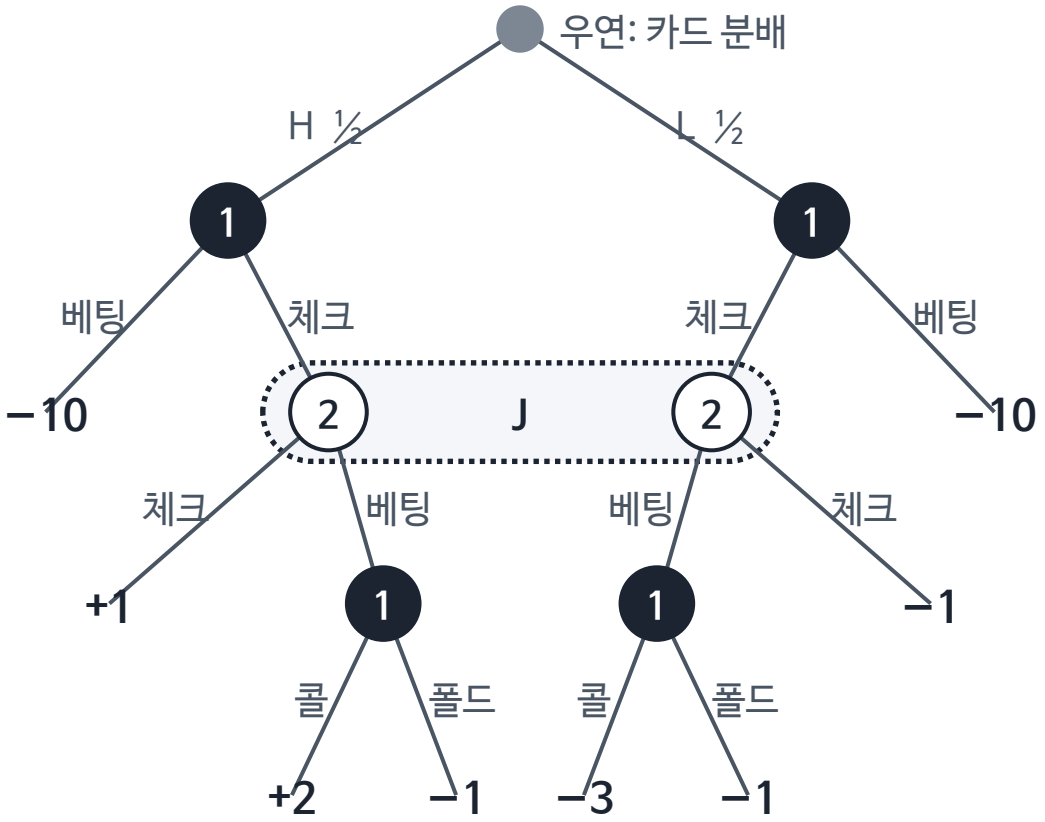
학습한 전략의 후회로
추상화를 스스로 나누는 방법



졸업 논문 연구 · 2인 영합 불완전 정보 게임의 적응형 추상화 · 2026년 11월

불완전 정보 게임과 정보집합

질문 1 · 정보집합이란?



플레이어 2는 카드를 모른다:
두 상태가 하나의 정보집합 J

게임 트리 · 카드 분배(우연)와 두 플레이어의 행동. 끝의 수는 플레이어 1의 보수(칩)

보는 것 / 못 보는 것 · 플레이어 1(●)은 자기 카드를 본다. 플레이어 2(○)는 행동만 본다

정보집합 (information set) · 그 플레이어가 서로 구별할 수 없는 상태들의 묶음

전략 (strategy) · 정보집합마다 행동 확률 하나. J의 두 상태에서는 같은 확률로 둔다

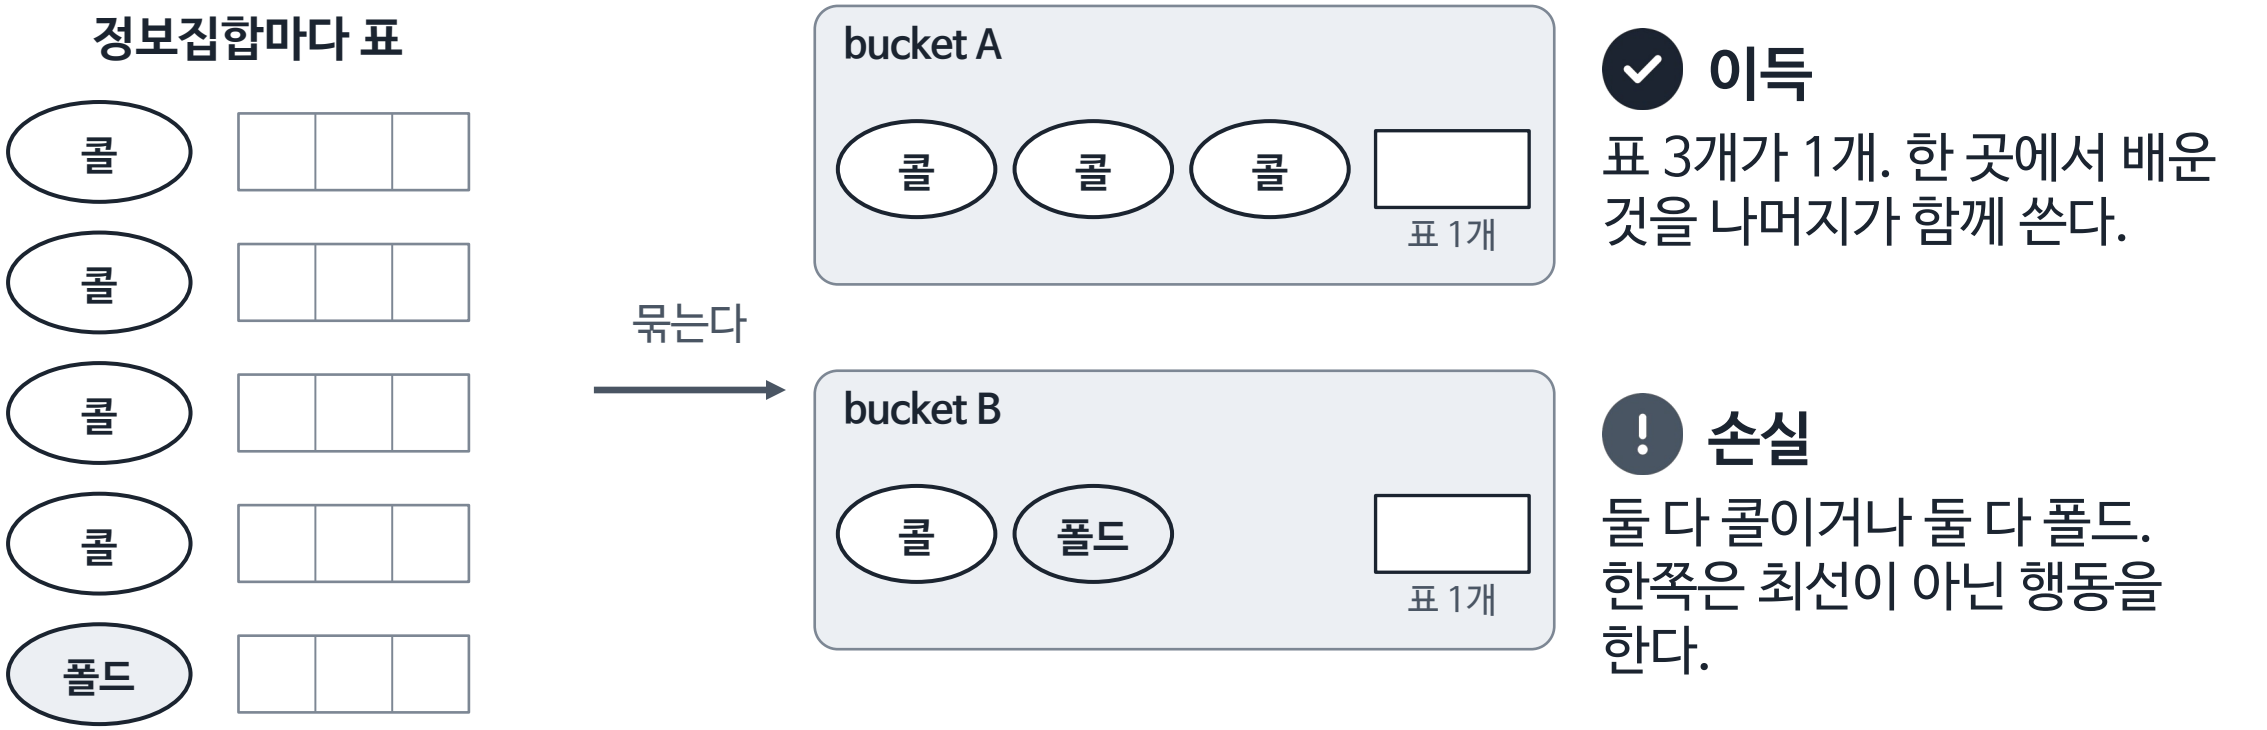
내시 균형 (Nash equilibrium) · 누구도 혼자 전략을 바꿔 이득을 볼 수 없는 상태

exploitability · 상대가 내 전략을 알고 최선으로 대응할 때 균형보다 더 잃는 양. 0이면 균형

정의는 일반 이론의 보충 설명이다.

추상화: 묶으면 얻는 것과 잃는 것

큰 게임은 정보집합이 너무 많다. 세븐 포커에서는 같은 정보집합이 학습 중 거의 다시 나오지 않아 정보집합마다 표를 둘 수 없다.



이득

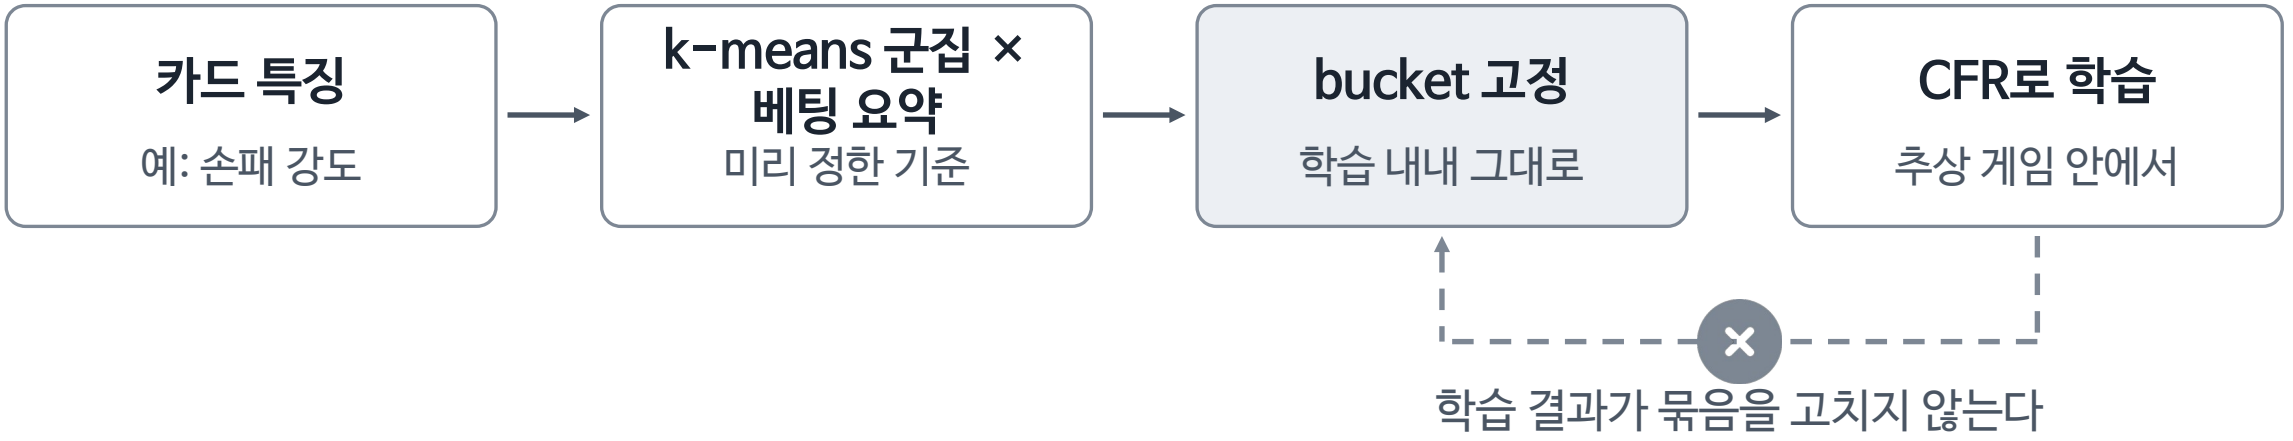
표 3개가 1개. 한 곳에서 배운 것을 나머지가 함께 쓴다.

손실

둘 다 콜이거나 둘 다 폴드. 한쪽은 최선이 아닌 행동을 한다.

추상화(abstraction): 정보집합을 bucket으로 묶는 분할. bucket 안의 정보집합은 한 전략을 함께 쓴다. 무엇을 묶느냐가 성능을 정한다.

고정 추상화에 빠져 있는 것



1 묶는 기준이 해를 보지 않는다

무엇을 합쳐도 되는지는 게임의 해(균형)가 정한다. 카드 특징은 그것을 모른다.

2 전략적 동등성의 보장이 없다

같은 bucket이 같은 행동을 원한다는 보장이 없다. 다르면 앞장의 손실이 생긴다.

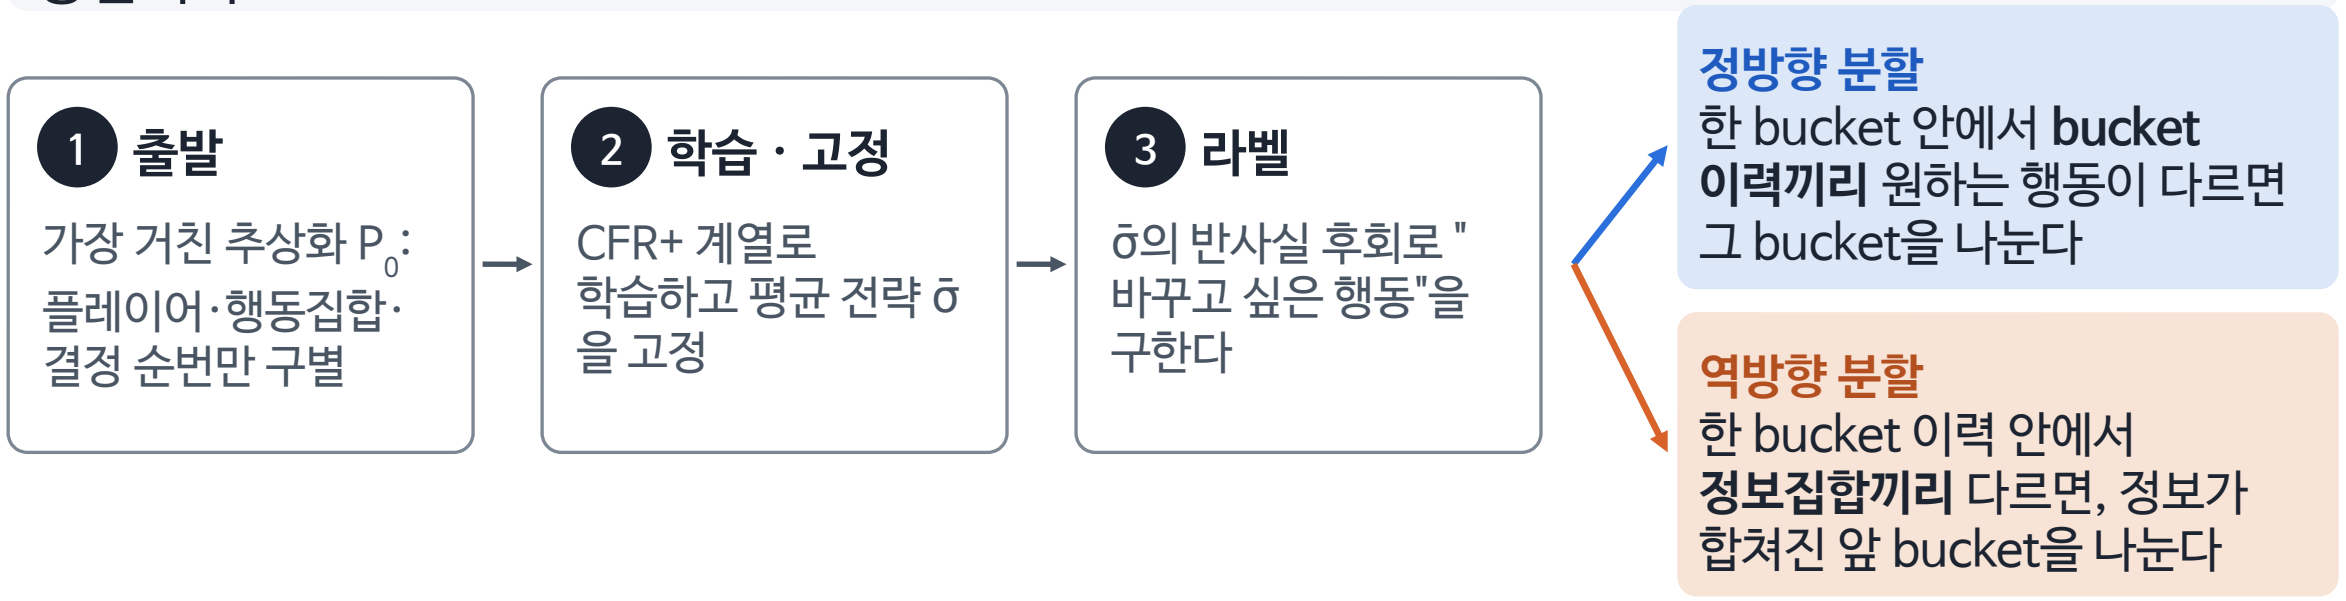
3 손실을 찾아 고칠 길이 없다

"여기는 다르게 두고 싶다"는 신호가 나와도 추상화는 바뀌지 않는다.

보충: 고정 추상화에서 학습기가 노리는 것은 추상 게임의 해다. 그것이 원 게임의 균형이라는 보장은 따로 없다.

ASWISS의 핵심 아이디어

ASWISS는 미리 정한 특징이 아니라 **학습된 전략의 반사실 후회**를 이용하여 정보집합의 분할 필요성을 판단하고, **정방향** 및 **역방향** **분할**로 추상화에 의해 숨겨진 전략적 차이를 복원하려는 방법이다.



다시 학습하고 판정한다. 아무것도 나뉘지 않으면 멈춘다 (**정지 상태**). 다음 장부터 후회 → 자료구조 → 예시 게임 순서로 한 단계씩 본다.

후회: 그 행동을 했더라면 얼마나 나았을까

예시 게임의 결정 2 (체크 → 상대 베팅 → 콜 또는 폴드). 지금 전략은 "항상 콜"이다.

카드	콜의 값	폴드의 값	폴드의 후회	× ½
H	+2	−1	−1 − (+2) = −3	**−1.5**
L	−3	−1	−1 − (−3) = **+2**	**+1.0**

후회 (regret) = 그 행동의 값 − 지금 전략의 값. 양수면 "바꾸고 싶다".

× ½ = 상대와 우연이 여기로 데려올 확률 (카드 ½ × 상대 베팅 1). 남의 확률만 곱하므로 **반사실 (counterfactual)** 값이라 한다.

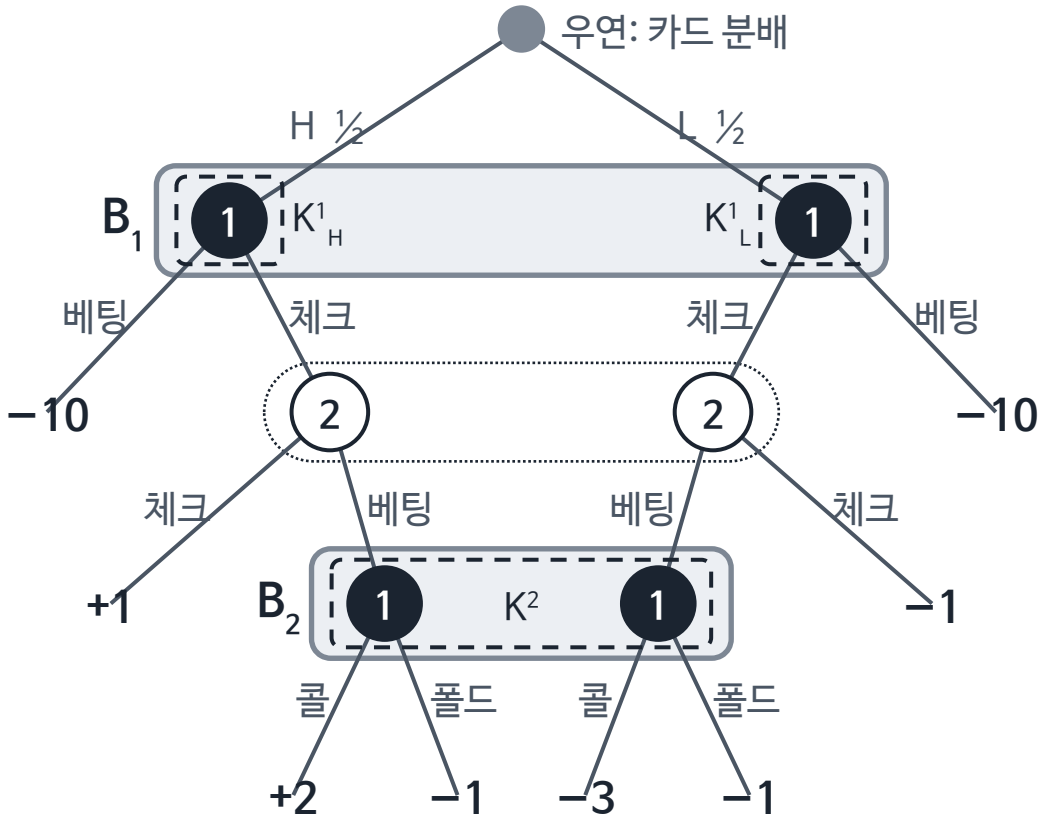
$r(I, a) = q(I, a) - \Sigma_b \sigma(I, b)\, q(I, b)$ $\quad q(I, a) = \Sigma_{h \in I} \pi_{-i}(h)$ · (h에서 a를 둔 뒤의 기대 보수)

CFR: 후회를 줄여 가는 반복

1. 지금 전략 σ^t로 끝까지 계산
2. 정보집합·행동마다 반사실 후회를 누적
3. 누적 후회가 양수인 행동을 그 비율로 둔다 (regret matching)
4. **반복한 전략들의 평균 $\bar{\sigma}$이 균형으로 간다**

보충 · 왜 평균인가: 지금 전략은 서로 쫓고 쫓기며 진동할 수 있다. 2인 영합·완전 기억 게임에서는 평균의 수렴이 보장된다.

bucket과 bucket 이력



1 **정보집합 I** · 게임이 정한 구별 단위 (여기서는 플레이어 1의 결정점 하나하나)

bucket B · 전략을 함께 쓰는 정보집합 묶음 = 추상 게임의 정보집합

bucket 이력 K · (지나온 bucket, 둔 행동, 새 관측). 과거는 bucket 번호로만 기억한다

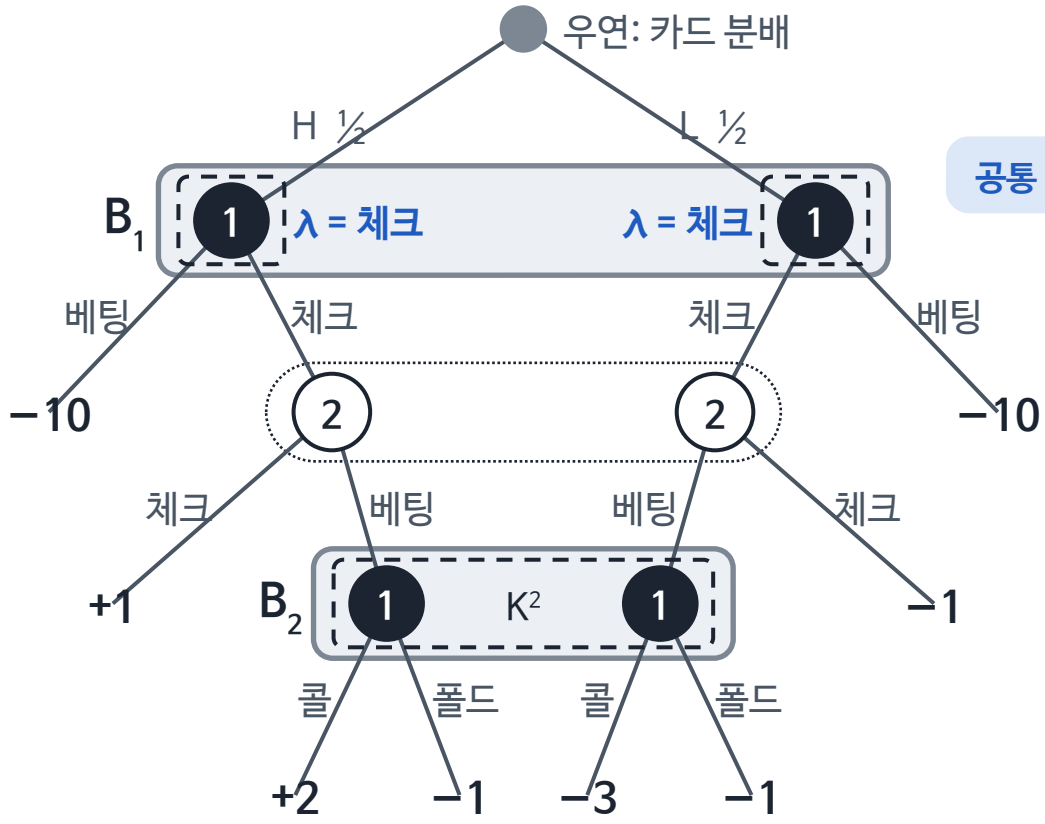
σ̄ · bucket마다 하나인 평균 전략 (판정 때 고정)
λ(K) · K에 모은 후회가 가장 큰 행동 = 라벨

B_1에는 이력이 둘: K^1_H = (카드 H), K^1_L = (카드 L)
B_2에는 이력이 하나: K^2 = (B_1, 체크, 상대 베팅)
→ 카드는 B_1에 합쳐져 B_2에서는 H와 L이 구별되지 않는다

출발점 P_0: (플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로 묶는 가장 거친 분할

정방향 분할: 이력끼리 라벨이 갈리면 나눈다

질문 4 · 어디를 나누나

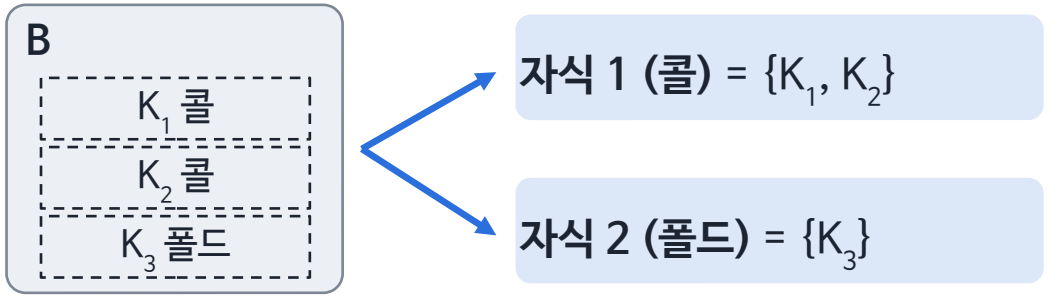


공통 라벨 → 유지

규칙 · 한 bucket 안의 이력들이 공통 라벨을 하나도 갖지 않으면 라벨별로 자식 bucket을 만든다.

라벨이 갈리는 경우 (설명용 예시 값)

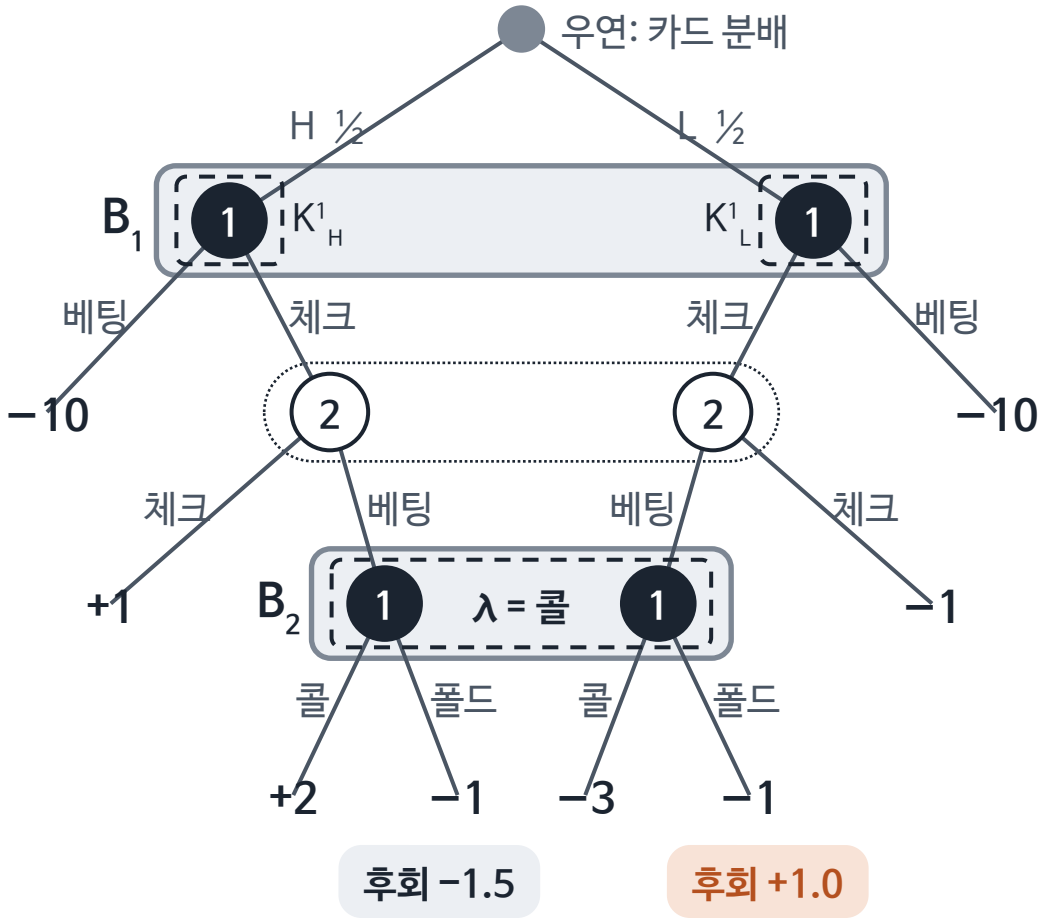
이력	폴드	콜	레이즈	라벨
K_1	−0.40	+0.70	+0.10	콜
K_2	−0.20	+0.35	−0.05	콜
K_3	+0.55	−0.30	−0.60	폴드



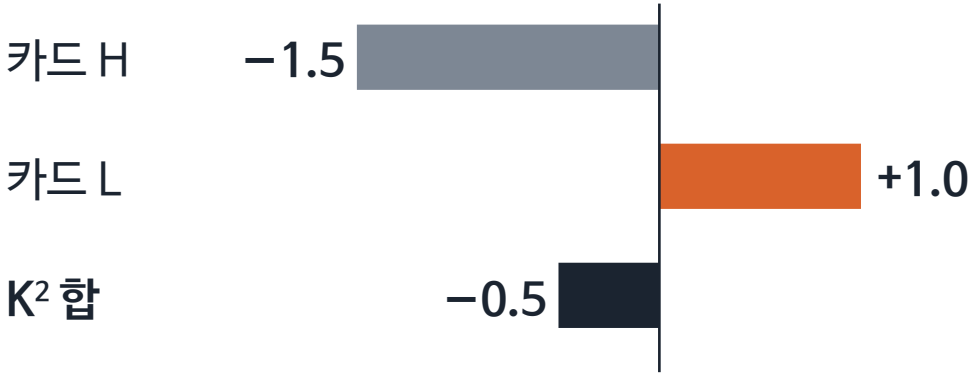
같은 이력은 절대 갈라지지 않는다 · 자식은 표를 새로 시작한다

왼쪽 게임: B_1의 두 이력 모두 "체크" → 유지 (옳다)

정방향 분할만으로는 멈출 수 있다 (명제 H4)



결정 2에서 폴드의 반사실 후회 (앞의 표)

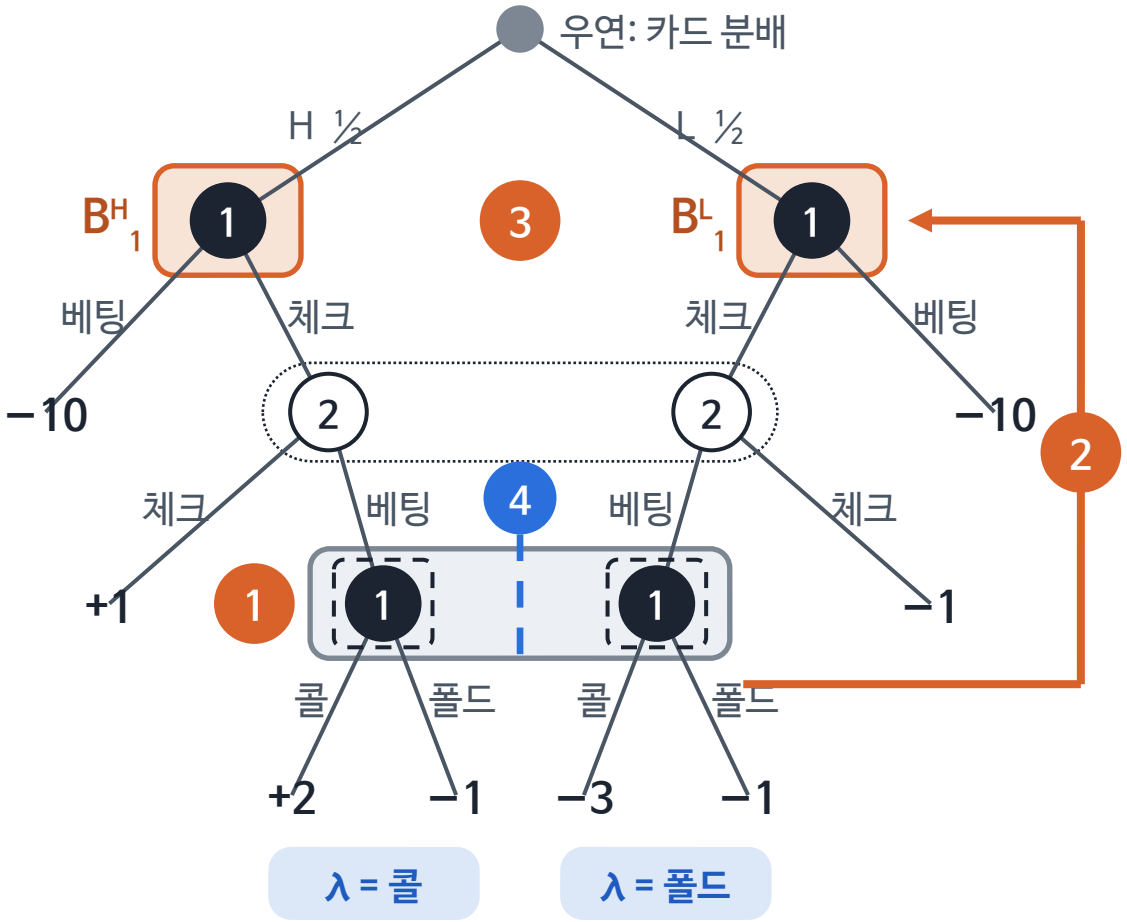


L은 폴드를 원하지만(+1.0) 같은 이력의 H와 더해져 사라진다. 라벨은 "콜"이고 B_2에는 이력이 하나뿐이라 나눌 것이 없다 → **정지**

그런데 L이 폴드로 바꾸면 1을 더 얻는다
→ **NashConv = 1**
NashConv = 각 플레이어가 혼자 바꿔 얻을 수 있는 이득의 합

Leduc에서도 정방향만 (+ 트리 유지) 쓰면 P_0에서 한 번도 나누지 못하고 exploitability 2.93에 머물렀다.

역방향 분할: 정보가 합쳐진 앞 bucket을 나눈다



1 **진단**
이력 K^2 안의 정보집합끼리 라벨이 갈린다: H는 콜, L은 폴드 ($H_K > 0$)

2 **거슬러 오르기**
이력이 달랐는데 같은 bucket에 묶인 앞 결정 → 결정 1의 B_1 (보조정리 H3)

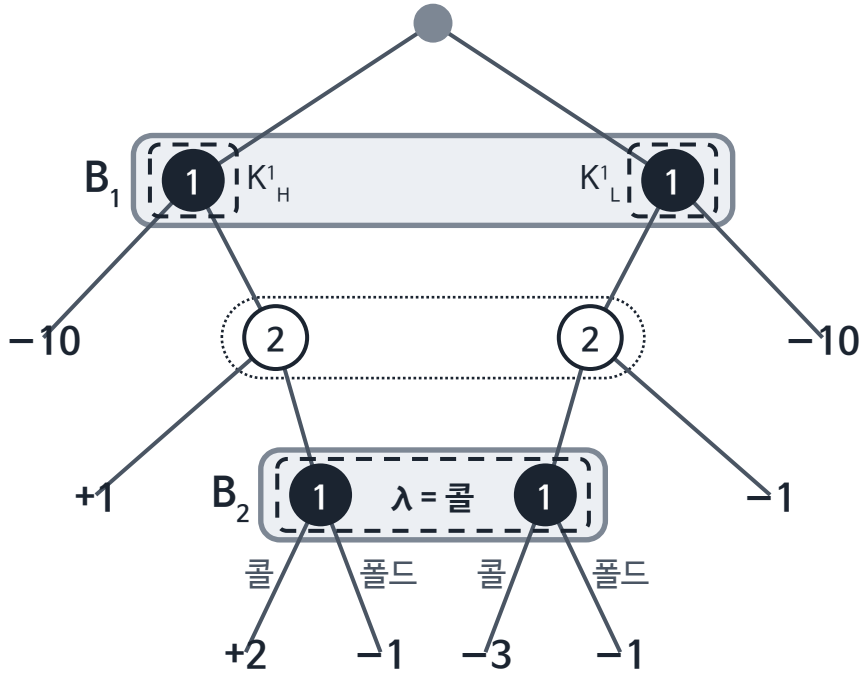
3 **역방향 분할**
B_1을 B^H_1, B^L_1로 나눈다. 정보집합은 그대로 두고, 뒤 결정의 이력이 갈라진다

4 **다음 판정**
결정 2의 이력이 둘로 갈라져, 정방향 분할이 B_2를 콜과 폴드로 나눈다

7-stud 구현은 정보집합이 반복되지 않아, 직전 결정의 bucket 이력으로 묶어 진단한다 (교차 검정). 부록 A5.

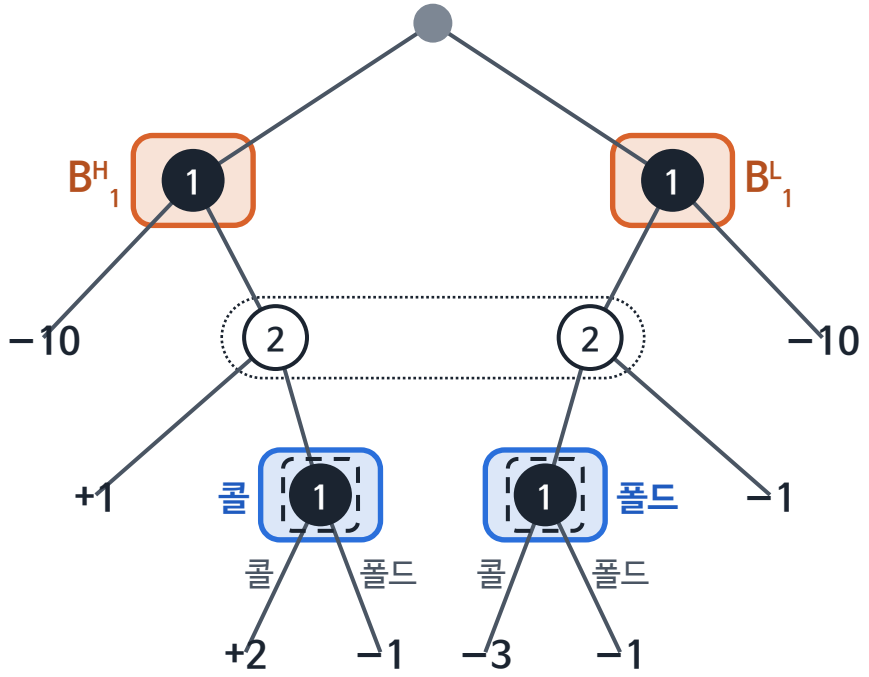
같은 게임, 두 결과: 정방향만 vs 역방향 포함

정방향만



정지 · NashConv = 1
L의 폴드 선호가 H와 상쇄되어 보이지 않는다

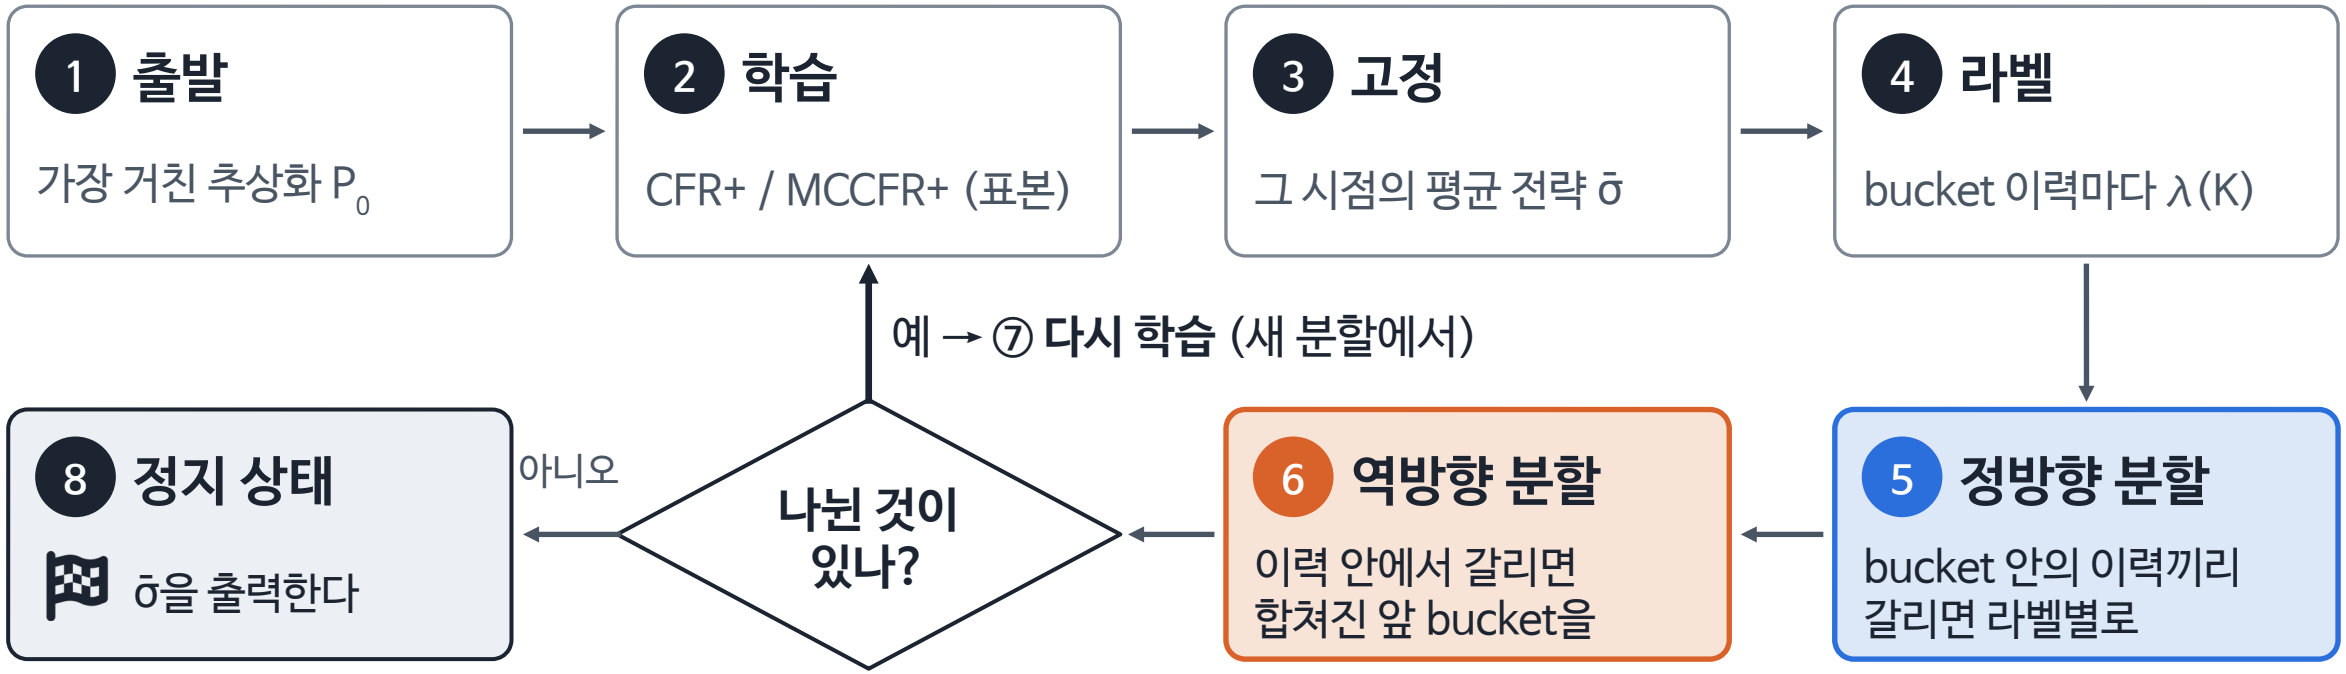
정방향 + 역방향



균형 · 원 게임 값 0 (H 콜, L 폴드, 상대 체크)
판정 두 번: 역방향(B_1) → 정방향(B_2)

알고리즘 흐름

질문 4 - 6 · 전체 절차



주의: 정지 상태는 "더 나눌 곳을 찾지 못한 상태"이지, 그 자체로 원 게임의 내시 균형이 아니다. 균형이 되려면 학습기가 bucket 후회를 ε 아래로 만들어야 한다 (정리 H5).

실험에서는 판정 문턱 없이 epoch마다(반복 수 두 배 간격) 판정했다.

의사코드와 정의

$P \leftarrow P_0$

repeat

  $\bar{\sigma} \leftarrow \text{Learn}(P)$ ▷ CFR+ / MCCFR+

  for each bucket 이력 K:

    $\lambda(K) \leftarrow \text{argmax}_a\, r^{\bar{\sigma}}(K, a)$ 또는 없음

  정방향: 이력들이 공통 라벨을 갖지 않는

    bucket을 라벨별로 나눈다

  역방향: 멤버의 라벨이 갈리는 K마다

    정보가 합쳐진 지점의 bucket을 나눈다

until 아무것도 나뉘지 않음

return $\bar{\sigma}$

P_0
(플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로

Learn
이론: $\rho_P \le \varepsilon$를 만드는 학습기로 가정한다. 실험: 문턱 없이 epoch마다 판정

라벨 λ(K)
분할 시점의 σ̄을 고정하고, 그 아래 순간 반사실 후회 $r^{\bar{\sigma}}(K, a) = \sum_{I \in K} r^{\bar{\sigma}}(I, a)$가 가장 큰 행동. 모두 0 이하면 "없음"

정지 상태
아무것도 나뉘지 않은 판정: 모든 $G_B = 0$이고 모든 $H_K = 0$

인증 부등식: 세 항이 각각 무엇을 막는가

정리 H1 (어떤 lifting된 전략 σ에도 성립)

$$\mathrm{NashConv}(\sigma) \le \rho_P(\sigma) + \Sigma_B G_B + \Sigma_K H_K$$

bucket 후회 ρ_P

bucket이 스스로 느끼는 후회의 합

→ 학습기 (CFR+)가 줄인다

bucket 안 상쇄 G_B

한 bucket 안에서 서로 다른 이력끼리 상쇄되어 사라진 후회

→ 정방향 분할이 0으로

이력 안 상쇄 H_K

한 이력 안에서 정보집합끼리 상쇄되어 사라진 후회

→ 역방향 분할이 0으로

정지 상태 ($G = 0, H = 0$)에서는 NashConv $\le \rho_P$. 학습기가 $\rho_P \le \varepsilon$를 주면 NashConv $\le \varepsilon$ (정리 H5, 조건부). 표본 라벨이면 인증에 $+ 4\Sigma_K \eta_K$ (정리 H6).

예시 게임 (명제 H4의 정지점)

$H_{K^2} = \max(0, -1.5) + \max(0, +1.0) - \max(0, -0.5) = 1 = \mathrm{NashConv}$

→ 남은 것은 전부 이력 안 상쇄였다

무엇이 증명되었고, 무엇이 조건부인가

질문 7 · 보장의 조건

증명 · 부등식	**H1 인증**: NashConv $\leq \rho_P + \Sigma\, G_B + \Sigma\, H_K$ · **H6 표본 판정**: 좋은 사건 위에서 거짓 분할이 없고 인증에 $+ 4\Sigma_K\, \eta_K$
증명 · 유한 종료	**H2**: 분할은 많아야 $N - \lvert P_0 \rvert$번 (N = 정보집합 수). 라벨이 추정이어도 같다
증명 · 반례와 동치	**H4**: 정방향만으로 NashConv = 1에서 멈추는 게임이 있다 · **H7**: 모든 bucket의 부모(직전 bucket, 행동)가 하나 ⇔ 추상화의 완전 기억
조건부 정리	**H5**: 학습기가 $\rho_P \leq \varepsilon$를 주고 라벨이 정확하면, 정방향 + 역방향은 NashConv $\leq \varepsilon$에서 멈춘다
실험적 수렴	Leduc 21/21 정지 상태, mini-stud ε = 0.2에서 정지 상태 도달, Kuhn 수렴. 관찰한 설정에서만 말할 수 있다 (증명 아님)
미해결	**학습기 조건**: CFR 평균은 자기가 가지 않는 곳의 후회 때문에 $\rho_P \leq \varepsilon$를 맞추지 못한다 (추상화 없는 Leduc도 $\rho/2$ = 0.0855에서 멈춤) · 표본 역방향 분할의 보장

명칭은 증명 초안(ASWISS_HISTORY_PROOF_KO.md)을 따른다. 정확한 가정과 진술은 부록 A2 – A6.

실험 설계: 다섯 가지 질문

질문 8 · 검증

	연구 질문	게임 (크기)	지표
A	역방향 분할이 bucket 이력 단위의 손실을 되찾는가?	mini-stud (정보집합 51,114)	exploitability (정확)
B	어떤 출발점에서도 정지 상태에 도달하는가?	Leduc (288), Kuhn	exploitability (정확)
C	트리 구조(완전 기억)는 무엇을 돕는가?	Leduc, 고정 추상화 96 bucket	D/2, exploitability
D	큰 게임에서 고정 추상화(k-means)와 비교하면?	7-stud 헤즈업 (5구부터)	LBR (근사 하한)
E	판정 문턱 ε가 도움이 되는가?	7-stud 5.11M roots	LBR (근사 하한)

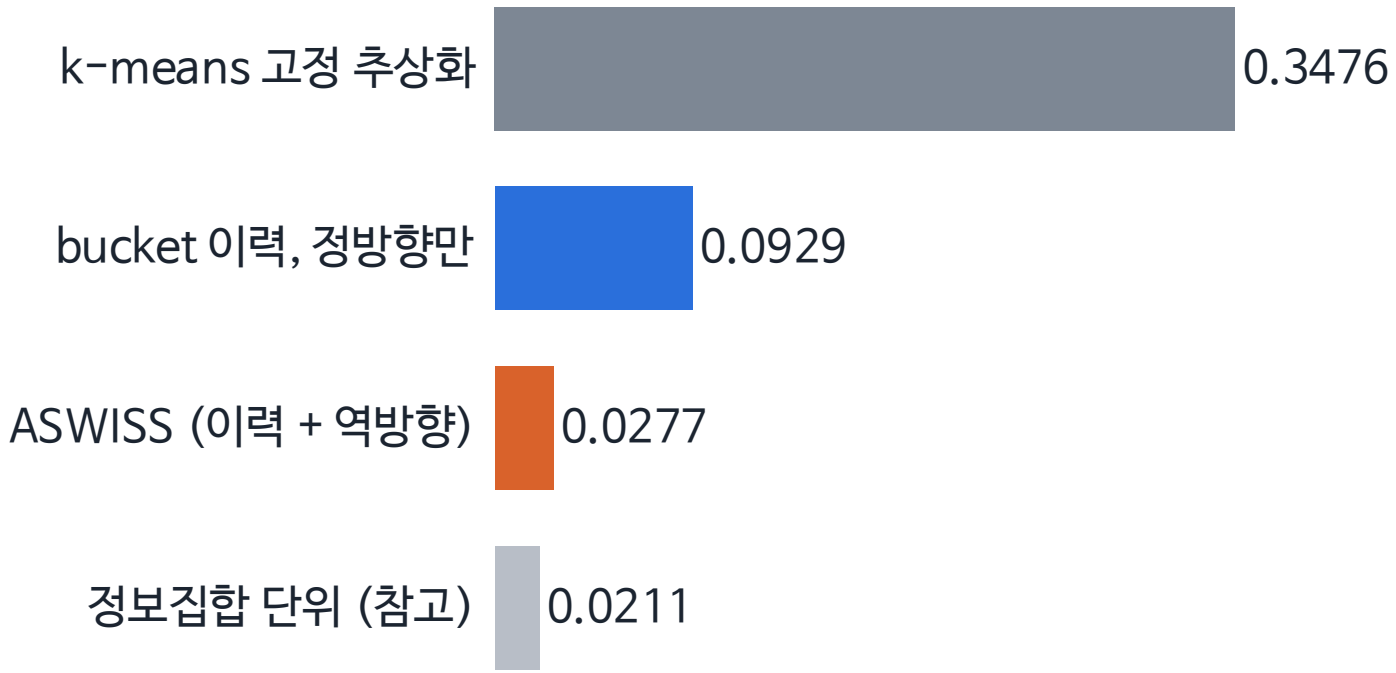
exploitability (정확)
원 게임에서 최선 대응에 잃는 양 (= NashConv / 2). 0이면 균형. 게임 트리 전체를 계산할 수 있는 작은 게임에서만 잴 수 있다.

LBR (local best response)
큰 게임용 근사. 최선 대응을 일부만 찾으므로 exploitability의 **하한**이다. 실제 값은 더 클 수 있다. 낮을수록 좋다.

A. mini-stud: 역방향 분할이 손실을 되찾았다

질문 8 · 검증

질문 A · 역방향 분할이 bucket 이력 단위의 손실을 되찾는가?



정보집합 51,114개 · 4,096만 반복 · seed 3개 평균 · 평균 정책의 정확한 exploitability (낮을수록 좋음) · 비교군마다 bucket 수가 다르다 (부록 A8)

3.4배

역방향 분할을 더하자 0.0929 → 0.0277

정지 상태 도달

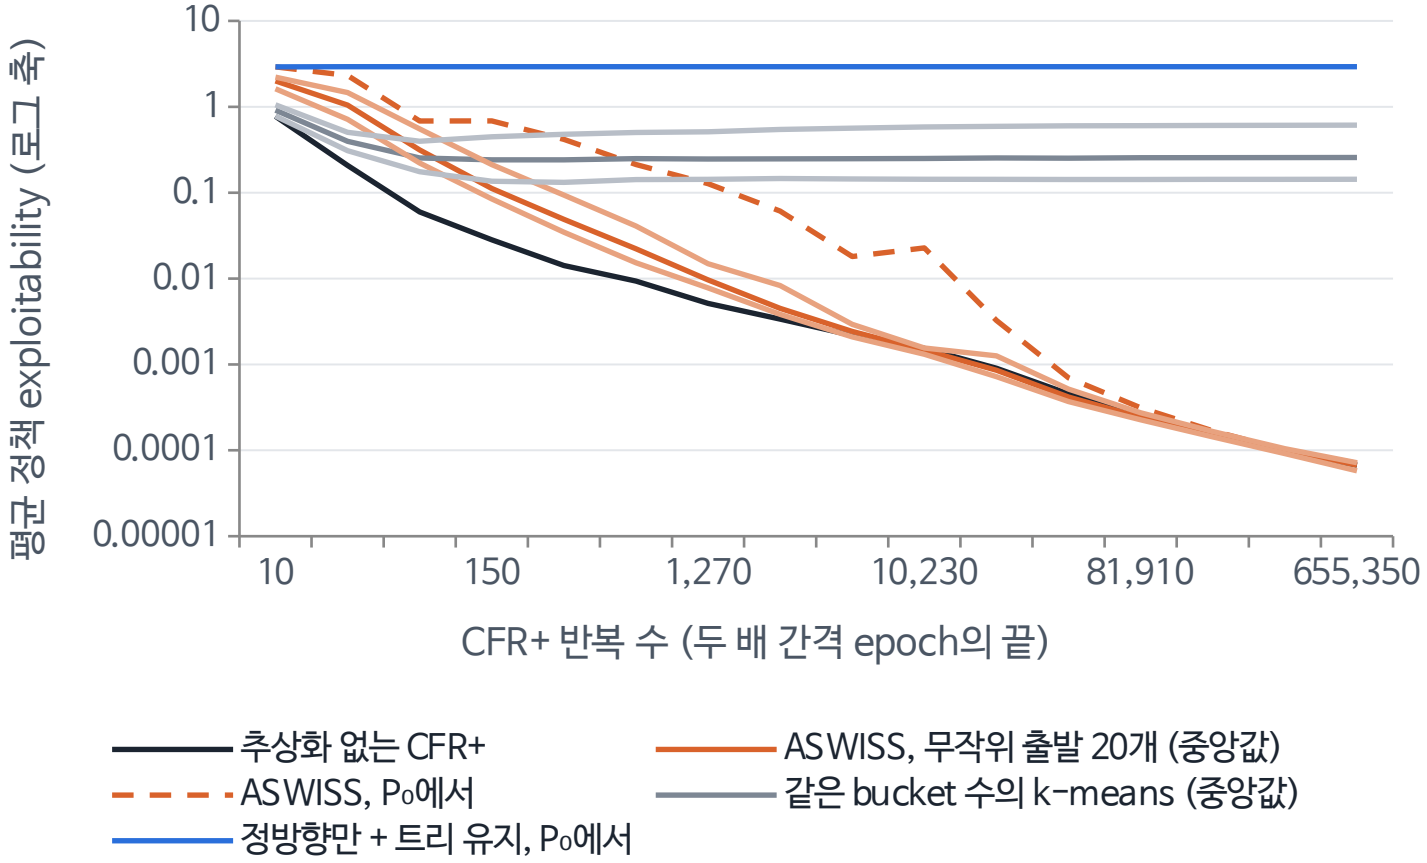
ε = 0.2 비교군: 2,900만 – 3,050만 반복에 G = 0, H = 0. 실제 0.034 – 0.038 ≤ 인증 0.19 – 0.20

0.0211

정보집합 단위 라벨이 조금 더 낮지만, 큰 게임에서는 정보집합이 반복되지 않아 쓸 수 없다

B. Leduc: 어떤 출발점에서도 정지 상태에 도달

질문 B · 가장 거친 분할이든 무작위 추상화든, 정지 상태와 낮은 exploitability에 도달하는가?



정확한 CFR+ · 정보집합 288 · 옅은 선: 무작위 출발 20개(및 짝지은 k-means)의 최소·최대

21 / 21

P_0와 무작위 출발 20개 모두 정지 상태 (G = 0, H = 0)

0.000067

65.5만 반복 뒤 exploitability. 추상화 없는 CFR+와 같다

203 – 270

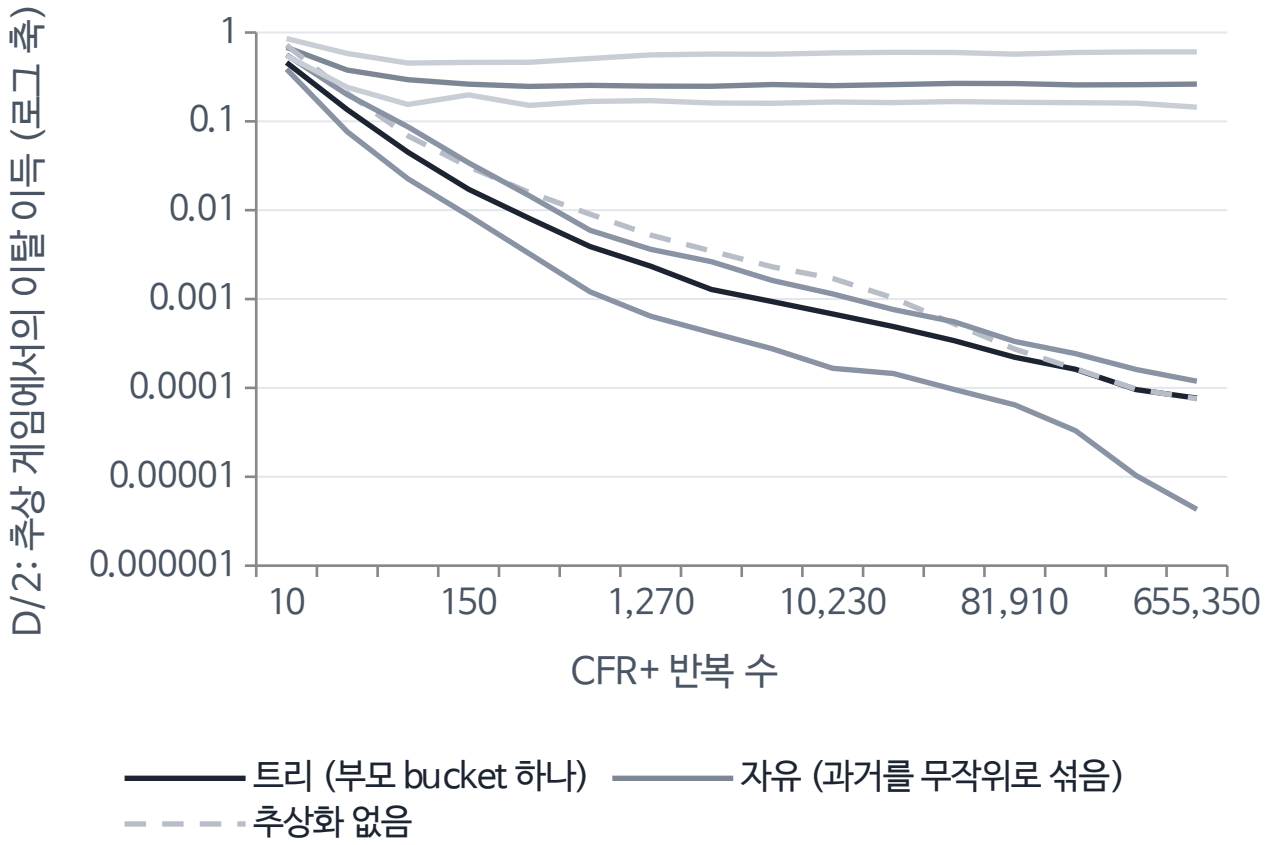
최종 bucket 수 (288개 중). 같은 수의 k-means는 0.14 – 0.88

이 설정에서 관찰한 결과이며, 수렴의 증명은 아니다.

C. 트리 구조와 역방향 분할의 역할

질문 8 · 검증

질문 C · 트리 구조(각 bucket의 부모가 하나 = 완전 기억)는 무엇을 돕고, 무엇을 돕지 않는가?



D = bucket 하나만 바꿔 얻는 이득의 합 (0이면 추상 게임을 푼 것) · Leduc, 고정 무작위 추상화 96 bucket, seed 10개 · 옅은 선: 최소·최대

65.5만 반복	트리	자유
D/2 (추상 게임)	**0.00008**	0.26
exploitability (원 게임)	1.81	1.74

학습기: 트리면 CFR+가 추상 게임을 푼다 (D → 0). 자유 추상화는 멈춘다.

원 게임: 그래도 트리가 낫지 않았다 (1.81 대 1.74). 추상 게임 성능 ≠ 원 게임 성능.

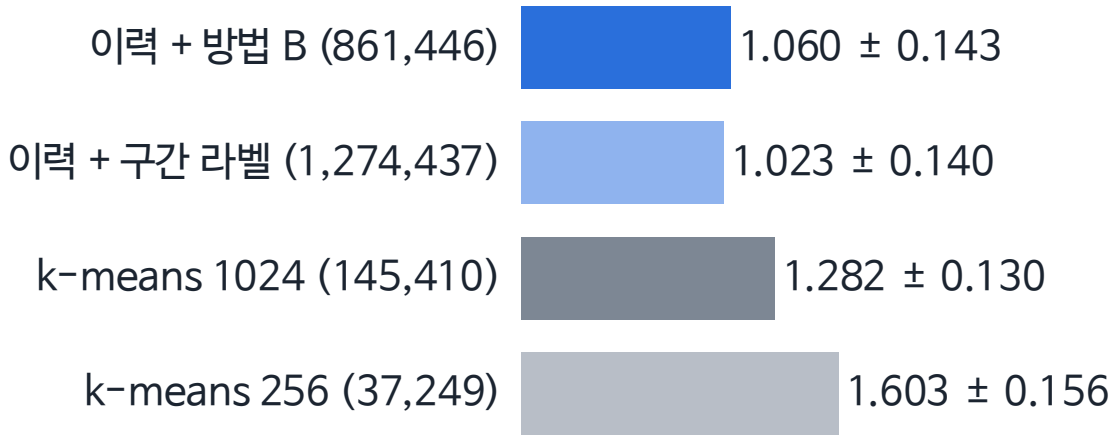
분할의 수렴: 정방향만 + 트리 유지는 P_0에서 2.93에 멈췄다. 역방향이 있으면 트리 여부와 상관없이 21/21 정지 상태.

D. 7-stud: 부분 구현과 완성형 시범을 나눠 본다

질문 8 · 검증

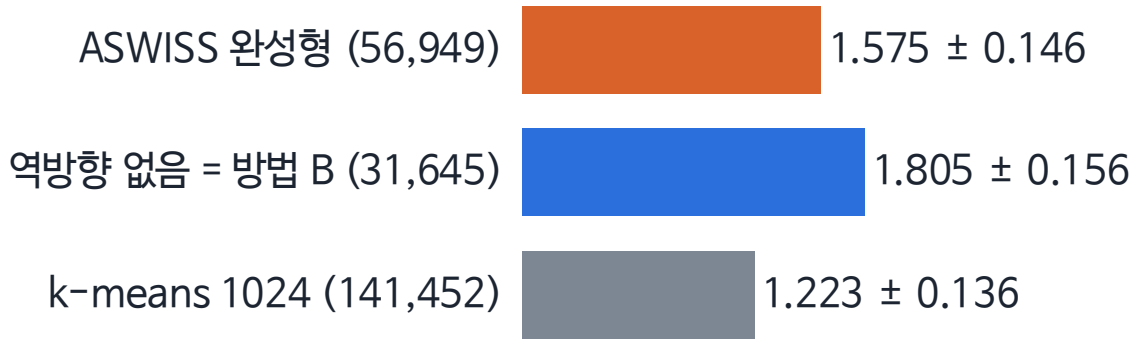
질문 D · 실제 크기의 게임에서 고정 추상화(k-means)와 비교하면?

100M roots · 역방향 없는 부분 구현



방법 B − k-means 1024 = **−0.22** [−0.41, −0.04] (같은 deal로 짝지은 차이). 이 실행에는 역방향 분할이 없다.

5.11M roots · ASWISS 완성형 시범



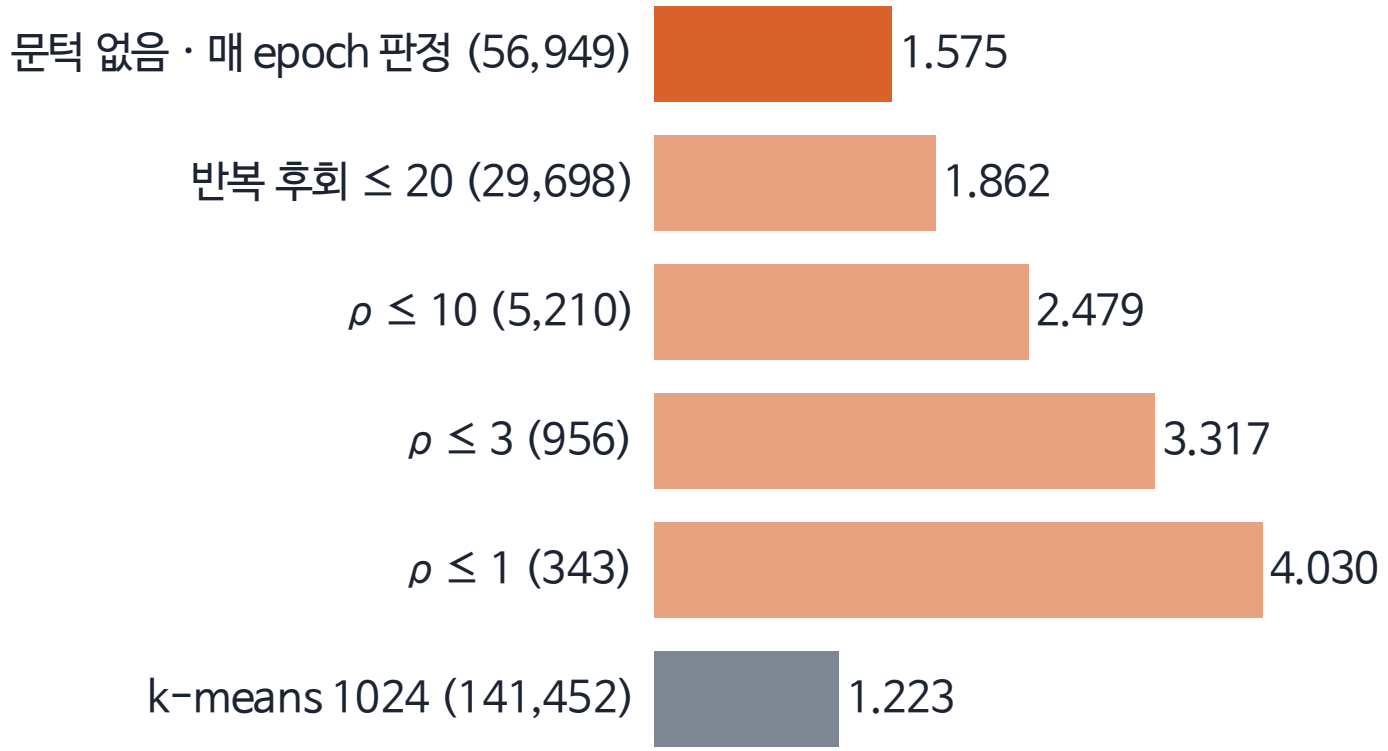
역방향 효과 **−0.23 ± 0.21**. 그러나 k-means 1024보다 아직 **+0.35 ± 0.19** 높다. 완성형의 100M은 아직 돌리지 않았다.

평균 정책 LBR (낮을수록 좋음, ± 95% 구간) · 괄호: bucket 수 · LBR은 exploitability의 근사 하한이다 · PolicyLBR 64 particles, 20,000 pair, seed 1 · 헤즈업, 5구부터 학습, 4구 버림·공개는 휴리스틱 · 두 패널은 학습량·bucket 수·버전이 달라 서로 비교하지 않는다

E. 판정 문턱: 엄격할수록 나빠졌다

질문 8 · 검증

질문 E · 학습기 조건을 흉내 내어, 후회가 작아질 때까지 판정을 미루면 좋아지는가?



7-stud 5.11M roots · 평균 정책 LBR, 20,000 pair (낮을수록 좋음) · 괄호: 마지막 bucket 수

엄격할수록 나빴다

문턱을 기다린 비교군은 모두 매 epoch 판정보다 LBR이 높았다. 기다리는 동안 bucket이 수십 – 수백 개에 묶여 있었다.

후회가 작다 ≠ 정책이 좋다

$\varepsilon = 1$은 bucket 36개, $\rho = 0.86$에서 통과했지만 LBR은 7.5로 같은 시점 k-means의 7.6배였다.

문턱의 뜻

이론에서 ε는 학습기 조건($\rho_P \leq \varepsilon$)이지 성능 지표가 아니다. 실험에서는 매 epoch 판정했다.

검증된 것과 아직 아닌 것

확인된 것

- **증명** · 인증 부등식(H1), 유한 종료(H2), 정방향만의 반례(H4), 표본 판정(H6), 트리 ⇔ 완전 기억(H7)
- **Kuhn · Leduc** · P_0와 무작위 출발 모두 정지 상태, 추상화 없는 CFR+와 같은 값 (관찰)
- **mini-stud** · 역방향 분할로 0.0929 → 0.0277 (seed 3개)
- **7-stud 100M** · 역방향 없는 bucket 이력(방법 B)이 k-means 1024보다 LBR 0.22 낮음 (seed 1)

아직 아닌 것

- **원 게임 보장** · H5의 학습기 조건을 CFR 평균이 만족한다는 증명이 없다
- **완성형의 큰 게임 성능** · 5.11M에서 k-means 1024보다 +0.35 높다. 100M은 미실행
- **표본 역방향 분할** · 7-stud는 직전 결정의 이력으로 묶는 약한 판정. 일반 보장 없음
- **평가의 한계** · LBR은 근사 하한, seed 1개, 4구 버림· 공개 휴리스틱
- **문턱과 절차** · 이론의 학습기 조건($\rho_p \le \varepsilon$)과 실험 절차(매 epoch 판정)가 다르다

정리와 다음 단계

학습된 전략의 반사실 후회로 나눌 곳을 정하고, **정방향**(bucket 안)과 **역방향**(이력 안) 분할로 추상화가 숨긴 전략적 차이를 되살린다.

요약

- 작은 게임: 어떤 출발점에서도 정지 상태, 추상화 없는 CFR+와 같은 값
- 큰 게임: bucket 이력은 고정 k-means를 넘었다 (역방향 없는 100M). 완성형은 시범 단계
- 이론: 인증과 종료는 증명. 원 게임 균형은 학습기 조건 아래에서만

다음 단계

1. 7-stud에서 역방향 분할을 넣은 ASWISS의 100M 실행
2. 카드 휴리스틱(power 군집) 제거: 카드를 한 장씩 관측으로
3. 학습기 조건을 경로 밖 후회 없이 다시 쓰기 (도달 가중 이득 D)
4. 표본 학습기 MCCFR+의 수렴 보장

A1. 기호와 정의

반사실 가치 $q^{\sigma}(I, a) = \sum_{h \in I} \pi^{\sigma}_{-i}(h) \sum_{z \sqsupset ha} \pi^{\sigma}(ha, z)\, u_i(z)$

순간 후회 $r^{\sigma}(I, a) = q^{\sigma}(I, a) - \sum_{b} \sigma(I, b)\, q^{\sigma}(I, b)$, $r^{\sigma}(I, \text{없음}) = 0$

모은 후회 $r(K) = \sum_{I \in K} r(I)$, $r(B) = \sum_{K \subseteq B} r(K)$

ψ와 라벨 집합 $\psi(x) = \max(0, \max_a x_a)$, $M(x) = \operatorname{argmax}_{\ell \in A \cup \{\text{없음}\}} x_\ell$. bucket B가 일치: $\bigcap_{K \subseteq B} M(r(K)) \neq \varnothing$

세 양 $\rho_P(\sigma) = \sum_B \psi(r(B))$, $G_B = \sum_{K \subseteq B} \psi(r(K)) - \psi(r(B))$, $H_K = \sum_{I \in K} \psi(r(I)) - \psi(r(K))$ (ψ가 준선형이라 $G, H \geq 0$)

bucket 이력 $\kappa_P(I) = (i, A(I), b(I^1), a^1, \cdots, b(I^m), a^m, o(I))$. 7-stud 구현: $(b(I^m), a^m, o(I))$ (직전 bucket만)

허용 분할: 모든 bucket이 이력류(같은 bucket 이력의 정보집합 묶음)의 합집합. $\mathbf{P_0}$: (플레이어, 행동집합, 자기 결정 순번)으로 묶음

NashConv$(\sigma) = \sum_i (\max_{\sigma' i} u_i(\sigma'_i, \sigma_{-i}) - u_i(\sigma))$. 실험의 exploitability = NashConv / 2

출처: 증명 초안 ASWISS_HISTORY_PROOF_KO.md §2. G는 완전 기억 유한 2인 영합 전개형 게임, σ는 lifting된 행동 전략($\sigma(I) = \sigma(b(I))$).

A2. 정리 H1 (인증)과 정리 H2 (유한 종료)

보조정리 H5 (NashConv 분해) · β_i를 σ_{-i}에 대한 순수 최선 응답이라 하면

$\mathrm{NashConv}(\sigma) = \sum_i \sum_{I \in \mathcal{I}_i} \pi^{\beta_i}_i(I)\, r^\sigma(I, \beta_i(I)) \le \sum_I \psi(r^\sigma(I))$

보조정리 H6 (두 단계 라벨 항등식) · 허용 분할과 임의의 σ에 대해

$\sum_I \psi(r(I)) = \rho_P(\sigma) + \sum_B G_B + \sum_K H_K$, 그리고 $G_B = 0 \Leftrightarrow$ B가 일치, $H_K = 0 \Leftrightarrow \bigcap_{I \in K} M(r(I)) \neq \varnothing$

정리 H1 (인증) · 임의의 허용 분할과 lifting된 σ에 대해

$\mathrm{NashConv}(\sigma) \le \rho_P(\sigma) + \sum_B G_B + \sum_K H_K$. 모든 bucket이 일치하면 $\mathrm{NashConv}(\sigma) \le \rho_P(\sigma) + \sum_K H_K$

정리 H2 (유한 종료) · 분할(역방향 포함)은 모든 표본 경로에서 많아야 $N - |P_0|$번이다.

증명: 분할마다 bucket 수가 엄격히 늘고, bucket 수는 N을 넘지 못한다. 라벨이 정확한지와 무관하다.

출처: 증명 초안 §5. H1은 H5와 H6을 잇는 것으로 증명된다. 상태: [증명].

A3. 조건부 결과와 학습기 조건

ε-오라클 가정 · 매 라운드 학습기가 $\rho_P(\bar{\sigma}) \le \varepsilon$인 lifting된 프로필을 낸다. 라벨은 정확히 계산한다.

정리 H3 (역방향 없이) · 이 가정 아래 분할 라운드는 많아야 $N - |P_0|$번이고, 멈춘 출력은 NashConv $\le \varepsilon + \sum_K H_K$. 모든 $H_K = 0$이면 NashConv $\le \varepsilon$.

정리 H5 (정방향 + 역방향) · 같은 가정 아래, 멈춘 출력은 NashConv $\le \varepsilon$. $\varepsilon = 0$이면 원 게임의 정확한 균형.

증명: 멈춤 = 정방향 분할 없음($G_B = 0$) + 역방향 분할 없음($H_K = 0$). 정리 H1에 넣는다.

오라클이 낼 프로필의 존재 · P_0에서 나뉜 분할은 같은 bucket의 두 정보집합이 한 경로 위에 있지 않으므로 $\rho_P = 0$인 프로필이 있다. 그러나 $H_K = 0$까지 함께 만족한다는 뜻은 아니다 (명제 H4).

학습기 조건 [미해결] · 표준 CFR 평균은 이 가정을 만족하지 않는다. 자기가 가지 않는 정보집합의 평균 전략이 거의 고쳐지지 않아 그곳의 후회가 남는다. 추상화 없는 Leduc에서도 CFR+ 평균의 $\rho/2$가 0.0855에서 멈췄다 (그때 exploitability 0.000067).

출처: 증명 초안 §6, §8, §11과 원본 슬라이드의 이론 표. 정리 H3은 원본 슬라이드에는 없고 증명 초안에만 있다.

A4. 합쳐진 지점, 역방향 규칙, 트리 구조

보조정리 H3 (정보가 합쳐진 지점) · $I \neq I'$이고 $\kappa(I) = \kappa(I')$이면 어떤 $j \le m$에서

$I^j \neq I'^j$, $\kappa(I^j) \neq \kappa(I'^j)$, $b(I^j) = b(I'^j)$. 즉 j번째 결정에서 이력은 달랐는데 같은 bucket에 들어갔다.

역방향 분할 규칙 · 이력류 K의 멤버들이 최대 라벨을 공유하지 않으면($H_K > 0$) 대표 라벨이 다른 두 멤버 I, I'을 고르고, 지점 j의 bucket $b(I^j)$에서 $\kappa(I^j)$를 떼어 자식 하나로 만든다. 그다음 라운드부터 I와 I'의 이력이 달라진다 (보조정리 H1).

구현(mini-stud·Leduc): 쌍은 첫 멤버와 라벨이 다른 멤버, 지점은 이력이 다른 가장 가까운 앞 결정. 역방향으로만 나뉜 자식은 부모의 표를 복사한다.

보조정리 H7 (트리 = 추상화의 완전 기억) · P가 P_0를 세분할 때, 모든 bucket의 멤버가 같은 (직전 자기 bucket, 행동)을 가지는 것과 같은 자기 과거 열 전체를 가지는 것은 동치다. 이때 CFR(+)는 추상 게임을 푼다. 그래도 정방향만으로는 멈출 수 있다 (명제 H4의 게임도 트리다).

출처: 증명 초안 §4, §8. 직전 bucket만 쓰는 bucket 이력(7-stud)에서도 H3은 $j_1 = \max\{j : \kappa(I\hat{}j) \neq \kappa(I'\hat{}j)\}$로 성립한다.

A5. 표본 판정 (정리 H6)과 구현의 차이

설정 · 라운드 k에서 σ을 고정하고, 두 좌석 모두 σ로 두는 외부 샘플링 순회를 n_k번 한다. 순회마다 방문한 정보집합의 표본 후회를 이력별로 더해 n_k로 나눈 것이 $\hat{r}(K)$.

집중 · 한 순회에서 이력류 K의 멤버는 많아야 하나 방문되므로 $\hat{r}(K)$는 불편 추정량이다. 확률 $1 - \delta$ 이상에서 모든 k, K, a에 대해

$$|\hat{r}(K, a) - r^{\bar{\sigma}}(K, a)| \le \eta^{(k)}_K = \Delta_K \sqrt{\left((2 / n_k) \ln(\pi^2 N_A (k+1)^2 / (3\delta) \right)}$$

정리 H6 · 여유 라벨(최대에서 2η 이내)로 판정하면, 좋은 사건 위에서 ① 참으로 일치하는 bucket은 나뉘지 않고 ② 나뉠 때 각 이력은 참 최대 라벨과 4η 이내인 자식으로 가며 ③ 분할 없는 라운드의 출력은 NashConv $\le \rho_P + 4\Sigma_K \eta_K + \Sigma_K H_K$ ④ 분할 수는 많아야 $N - |P_0|$.

7-stud 구현과의 차이 · 순회 수에 상한(epoch당 256만 roots)이 있어 η가 0으로 가지 않는다. 여유 라벨 대신 $z = 2$ 정규 근사 검정을 써서 거짓 분할이 있을 수 있다 (종료는 깨지지 않지만 bucket이 는다). 역방향은 정보집합 대신 직전 결정의 이력으로 묶고, 두 세부 이력이 서로 자기 라벨을 유의하게 선호할 때만 나눈다 (교차 검정). 일반 보장은 [미해결].

출처: 증명 초안 §9, §8과 원본 슬라이드의 역방향 설명. 상태: H6 [증명], 표본 역방향 [미해결].

A6. 명제 H4 게임의 계산

위치	계산 (σ^*: 플레이어 1은 체크 후 콜, 플레이어 2는 베팅)	결론
결정 1, 카드 H	베팅의 후회 $\frac{1}{2}(-10-2) = -6$	라벨 {체크, 없음}
결정 1, 카드 L	베팅의 후회 $\frac{1}{2}(-10+3) = -3.5$	라벨 {체크, 없음} → B_1 일치
결정 2, 카드 H	폴드의 후회 $\frac{1}{2}(-1-2) = -1.5$	
결정 2, 카드 L	폴드의 후회 $\frac{1}{2}(-1+3) = +1.0$	
결정 2, 이력 K^2	합 −0.5	라벨 {콜, 없음} → 나뉘지 않음
플레이어 2 (J)	베팅으로 0.5를 더 얻는다	후회 없음
결과	$\rho_P(\sigma^*) = 0$, 모든 bucket 일치, $\mathrm{NashConv}(\sigma^*) = 1 = H_{K^2}$	정방향만으로는 정지
원 게임 균형	H 콜, L 폴드, 플레이어 2 체크. 플레이어 1의 값 0 (σ^*에서는 −0.5)	역방향 → 정방향 두 판정 뒤 도달

출처: 증명 초안 §7 – §8. 덜 극단적인 경우(베팅 보상 −1)에는 L의 첫 결정에서 베팅이 나아 B_1 이 정방향으로 나뉘고 문제가 저절로 풀린다.

A7. 실험 설정

	mini-stud	Kuhn · Leduc	7-stud
게임	정보집합 51,114	Leduc 정보집합 288 (rank만)	헤즈업, 5구부터 학습
학습기	MCCFR+ (외부 샘플링), 라벨은 정확 계산	정확한 전체 트리 CFR+	MCCFR+ (외부 샘플링), 라벨은 표본
학습량	4,096만 반복	65만 5,350반복	100M roots / 5.11M roots
seed	3	P_0 + 무작위 출발 20 (Leduc)	1
판정	epoch마다 (두 배 간격)	epoch마다	epoch마다, 라벨 표본 상한
지표	평균 정책 exploitability	평균 정책 exploitability, D/2	평균 정책 LBR (64 particles, 20,000 pair)
비교군	k-means 고정, 정보집합 단위, 이력 정방향만	같은 bucket 수의 k-means, 정방향만 + 트리 유지	k-means 256 / 1024, 방법 B, 구간 라벨

출처: 원본 슬라이드와 aswiss/README_KO.md, aswiss/small/README_KO.md, aswiss/stud7/README_KO.md. 4구 버림·공개는 휴리스틱 (power 군집).

A8. 비교 조건의 차이 (같은 조건의 비교가 아닌 것)

mini-stud 비교군 (4,096만 반복)	bucket 수 (seed 1/2/3)
정보집합 단위, 매 epoch	12,683 / 12,839 / 12,888
bucket 이력, 정방향만	12,895 / 13,132 / 13,158
bucket 이력 + 역방향 (ASWISS)	15,745 / 16,304 / 15,811
카드 k-means 고정	7,051

mini-stud의 대가: 역방향 분할 뒤 $H_K = 0$이 되었을 때 bucket 이력이 정보집합의 99.4 – 99.8%를 구별했다. 이 게임에서 $H_K = 0$을 얻으려면 이력이 사실상 정보집합을 다 기억해야 했다. 큰 게임에서도 그런지는 미해결.

7-stud에서 다른 것

- 100M과 5.11M은 학습량과 버전(역방향 유무)이 다르다
- 같은 패널 안에서도 bucket 수가 다르다 (예: 86만 대 14.5만)
- 5.11M에서는 k-means 256도 측정했지만 여기서는 더 강한 k-means 1024만 보였다

맞춘 것: 같은 deal, LBR seed, 64 particles, 20,000 pair로 평가했고 평균 정책끼리 비교했다

비율 (원본 값으로 계산): 100M 방법 B / k-means 1024 = 0.83, 5.11M 완성형 / k-means 1024 = 1.29

원본 PDF에 없던 수: mini-stud bucket 수(aswiss/README_KO.md)와 99.4 – 99.8% (증명 초안 §8). 비율은 원본 값에서 계산했다.

A9. 판정 문턱 실험의 세부

mini-stud (정확 계산, 1만 반복마다 검사)

ε = 0.2 + 역방향: 29 – 30.5M에 "문턱 통과 + 모든 bucket 일치 + H_K = 0" 판정 (세 seed). 인증 $\rho/2$ = 0.19 – 0.20, 실제 NashConv/2 = 0.034 – 0.038

역방향이 없으면 같은 상태에서 $H_K/2 \approx 0.40$이 남아 인증 0.59 – 0.60, 실제 값도 두 배

- CFR 평균은 계속 바뀌므로 학습을 이어 가면 라벨이 다시 갈려 분할이 이어졌다

ε = 0.05, 0.1은 4천만 반복 동안 판정이 5 – 8번뿐. $\varepsilon/\sqrt{t}$ 문턱은 고정 분할에서 ρ도 $t^{-1/2}$로 줄어 추상화를 얼린다

7-stud (표본, 5.11M roots, seed 1)

- ε = 1: bucket 36개, $\hat{\rho}$ = 0.86에서 통과했지만 LBR 7.5 (같은 시점 k-means 1024의 7.6배)
- 자식이 많이 생기면 ρ가 크게 뛴다 (149 → 956 bucket 판정 직후 2.40 → 54.0)
- 학습 순회의 표본 후회 합은 오라클 조건을 대신하지 못한다

출처: 원본 슬라이드(ε = 1, 정지 상태 도달)와 증명 초안 §6. 원본 PDF에 없던 수: 0.40, 0.59 – 0.60, 5 – 8번, 2.40 → 54.0.

A10. 원본 이후 작업 (참고): 라벨용 혼합 평균

원본 PDF에 없는 내용이다. 발표 본문에서는 쓰지 않았다.

문제 · 평균 전략은 자기가 거의 가지 않게 된 곳에서 초반 값에 멈춘다. 정책에는 영향이 없지만(실현 계획의 질량이 0), 자주 가는 정보집합의 라벨이 그 아래의 멈춘 값으로 계산되어 "그 행동이 사실 더 좋다"는 분할 신호를 놓친다.

규칙 (--avg-fill plain) · 판정에 쓰는 전략만 바꾼다. 평균 전략으로 자기 도달확률이 10^{-4} 이상인 곳은 평균 전략, 그보다 작은 곳은 그 bucket의 현재 전략들의 단순 평균. 내놓는 정책은 그대로다.

지금까지의 결과 · 명제 B4(a) 반례: 평균 전략만으로는 끝까지 안 나뉘었고(NashConv 1), 혼합 평균으로는 150반복에 나뉘어 0으로 수렴. Leduc 21개 출발점: 정책과 bucket 수는 그대로, 판정에 쓴 평균의 $\rho_p/2$가 0.090 → 0.00029. mini-stud: 차이 없음 (0.0277 → 0.0271).

한계 · 이력 안 상쇄(명제 H4)는 풀지 못한다. 문턱 10^{-4} 한 값만 시험했다. 증명은 없다. 7-stud 100M 비교(hist_bbf 대 hist_bb)는 진행 중이다.

출처: aswiss/AVG_FILL_KO.md. 필요 없으면 이 장은 지워도 본문에 영향이 없다.