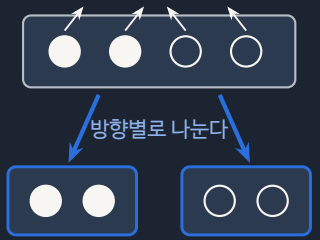
ASWISS

Abstraction Split WIth Sampling by Strategy

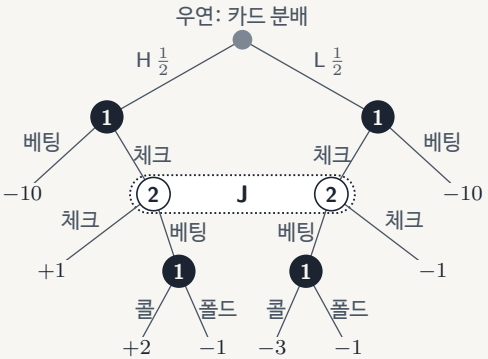
업데이트 방향이 갈리는 곳에서 추상화를 나누는 방법



작은 화살표: 각 정보집합의 업데이트 방향

졸업 논문 연구 · 2인 영합 불완전 정보 게임의 적응형 추상화 · 2026년 11월

불완전 정보 게임과 정보집합



플레이어 2는 카드를 모른다:
두 상태가 하나의 정보집합 J

게임 트리 · 카드 분배(우연)와 두 플레이어의 행동. 끝의 수는 플레이어 1의 보수(칩)

보는 것 / 못 보는 것 · 플레이어 1(●)은 자기 카드를 본다. 플레이어 2(○)는 행동만 본다

정보집합 (information set) · 그 플레이어가 서로 구별할 수 없는 상태들의 묶음

전략 (strategy) · 정보집합마다 행동 확률 하나. J의 두 상태에서는 같은 확률로 둔다

내시 균형 (Nash equilibrium) · 누구도 혼자 전략을 바꿔 이득을 볼 수 없는 상태

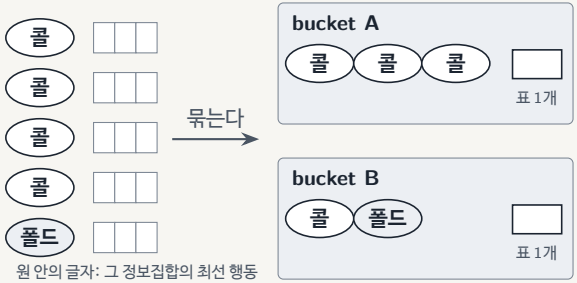
exploitability · 상대가 내 전략을 알고 최선으로 대응할 때 균형보다 더 잃는 양. 0이면 균형

정의는 일반 이론의 보충 설명이다.

추상화: 묶으면 얻는 것과 잃는 것

큰 게임은 정보집합이 너무 많다. 세븐 포커에서는 같은 정보집합이 학습 중 거의 다시 나오지 않아 정보집합마다 표를 둘 수 없다.

정보집합마다 표



원 안의 글자: 그 정보집합의 최선 행동

✓ 이득

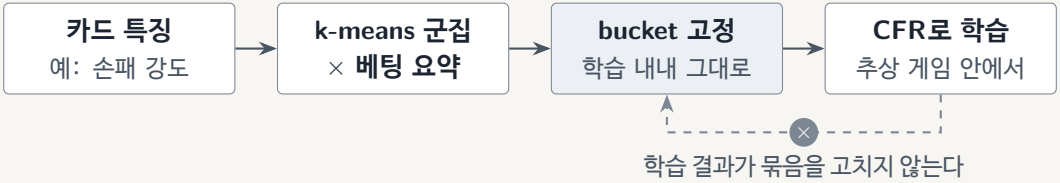
표 3개가 1개. 한 곳에서 배운 것을 나머지가 함께 쓴다.

! 손실

둘 다 콜이거나 둘 다 폴드. 한쪽은 최선이 아닌 행동을 한다.

추상화 (abstraction): 정보집합을 bucket으로 묶는 분할. bucket 안의 정보집합은 한 전략을 함께 쓴다. 무엇을 묶느냐가 성능을 정한다.

고정 추상화에 빠져 있는 것



❶ 묶는 기준이 해를 보지 않는다

무엇을 합쳐도 되는지는 게임의 해(균형)가 정한다. 카드 특징은 그것을 모른다.

❷ 전략적 동등성의 보장이 없다

같은 bucket이 같은 행동을 원한다는 보장이 없다. 다르면 앞 장의 손실이 생긴다.

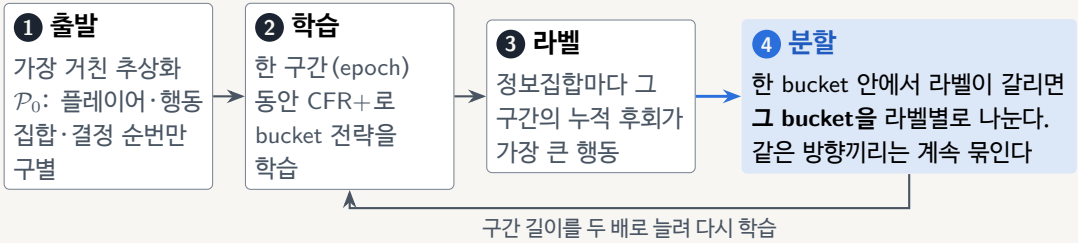
❸ 손실을 찾아 고칠 길이 없다

"여기는 다르게 두고 싶다"는 신호가 나와도 추상화는 바뀌지 않는다.

보충: 고정 추상화에서 학습기가 노리는 것은 추상 게임의 해다. 그것이 원 게임의 균형이라는 보장은 따로 없다.

ASWISS의 핵심 아이디어

ASWISS는 미리 정한 특징이 아니라 **학습 중인 전략의 업데이트 방향**(누적 반사실 후회가 가장 큰 행동)으로 정보집합을 판정하고, 한 bucket 안에서 **방향이 갈리면 그 bucket을 그 자리에서** 방향별로 나눈다.



분할은 유한 번에 끝나고, 그 뒤로 평균 전략은 **원 게임의 균형**으로 수렴한다 (정리 1). 다음 장부터 후회 → 라벨 → 예시 게임 순서로 본다.

후회: 그 행동을 했더라면 얼마나 나았을까

예시 게임의 결정 2 (체크 → 상대 베팅 → 콜 또는 폴드). 지금 전략이 "항상 콜"인 한 반복을 보자.

카드	콜의 값	폴드의 값	폴드의 후회	$\times\frac{1}{2}$
H	$+2$	-1	$-1-(+2)=-3$	$\mathbf{-1.5}$
L	-3	-1	$-1-(-3)=+2$	$\mathbf{+1.0}$

후회 (regret) = 그 행동의 값 − 지금 전략의 값. 양수면 "바꾸고 싶다".

$\times\frac{1}{2}$ = 상대와 우연이 여기로 데려올 확률 (카드 $\frac{1}{2}\times$ 상대 베팅 1). 남의 확률만 곱하므로 **반사실 (counterfactual)** 값이라 한다.

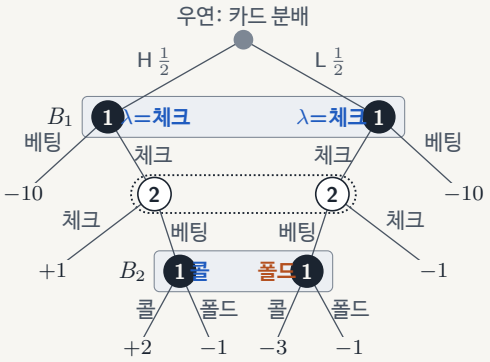
CFR: 후회를 줄여 가는 반복

1. 지금 전략 σ^t로 끝까지 계산
2. 정보집합·행동마다 반사실 후회를 누적
3. **누적 후회가 양수인 행동의 확률을 올린다** (regret matching) = **업데이트 방향**
4. **반복한 전략들의 평균 $\bar{\sigma}$이 균형으로 간다**

보충: 지금 전략은 진동할 수 있다. 2인 영합·완전 기억 게임에서는 평균의 수렴이 보장된다.

$r_t(I,a)=q_t(I,a)-\sum_b \sigma_t(I,b)\,q_t(I,b)$, $\quad q_t(I,a)=\sum_{h\in I}\pi_{-i}^{\sigma_t}(h)\cdot(h$에서 a를 둔 뒤의 기대 보수$)$

라벨: 정보집합마다의 업데이트 방향



출발점 $\mathcal{P}_0$: (플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로 묶는 가장 거친 분할. 이 게임에서는 B_1, B_2, $\{J\}$

1 정보집합 I · 라벨을 매기는 단위

bucket B · 전략을 함께 쓰는 정보집합 묶음

구간 누적 후회 $R_I^W(a) = \sum_{t \in W} r_t(I, a)$

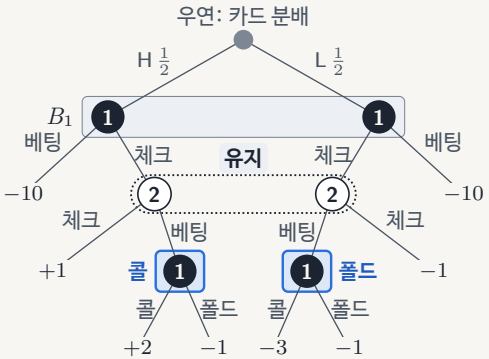
구간 W동안 반복 전략 σ^t 아래의 반사실 후회를 더한 것

라벨 $\lambda(I) = \arg\max_a R_I^W(a)$ **(양수일 때),**
아니면 "없음"

표본으로 추정하면 검정을 통과할 때만 (부록 A1)

B_1: H와 L 모두 체크 → **방향이 같다**
B_2: H는 콜, L은 폴드 → **방향이 갈린다**

분할: 방향이 갈린 bucket을 그 자리에서 나눈다



규칙 · 한 bucket의 정보집합들이 공통 라벨을 하나도 갖지 않으면, 그 bucket을 라벨별 자식으로 나눈다.

- 같은 라벨끼리는 계속 묶인다 (예: 콜 2개 + 폴드 1개 → 자식 2개)
- 정보집합은 bucket을 옮기지 않는다. 나누기만 하고 합치지 않는다
- 자식은 표를 새로 시작한다
- 앞 결정의 bucket은 건드리지 않는다

예시 게임: B_2를 **콜(H) / 폴드(L)**로 나눈다. 다음 구간부터 H는 콜, L은 폴드를 따로 배우고, 상대는 체크가 낫게 된다 → **원 게임의 균형** (플레이어 1의 값 0)

소속: 정보집합은 어느 bucket으로 가는가

작은 게임: 표로 기록한다

분할할 때 각 정보집합이 받은 라벨로 자식을 정하고, 정보집합 → bucket 표에 기록한다. 이후 그 정보집합은 늘 그 bucket의 전략을 쓴다.

정리 1이 다루는 경우다. mini-stud(51,114개), Leduc(288개)에서 그대로 쓴다.

큰 게임: 소속 규칙이 따로 필요하다

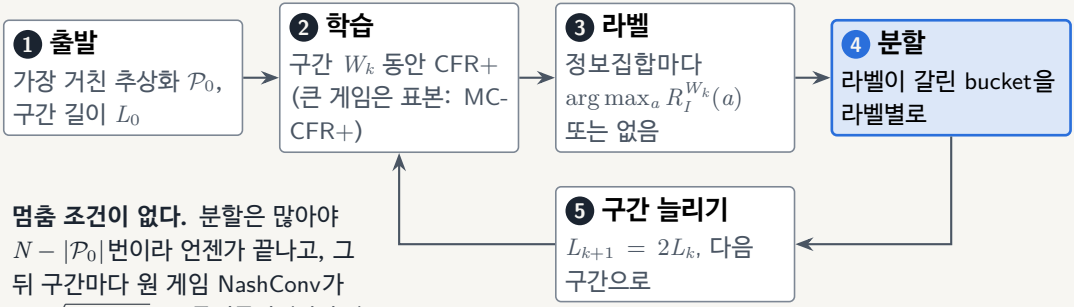
세븐 포커에서는 같은 정보집합이 학습 중 거의 다시 나오지 않는다.

- 라벨을 매길 표본이 정보집합마다 거의 없다
- 처음 보는 정보집합의 bucket을 표로 찾을 수 없다

후보: 저장한 전략으로 그 정보집합의 라벨을 다시 계산하기(부록 T1), 더 싼 키로 근사하기(bucket 이력, 원자: 부록 T2, T4)

이 발표의 본문(정리와 실험)은 **정보집합 단위**다. 큰 게임에서 정보집합 단위의 라벨과 소속을 싸고 일관되게 정하는 방법은 **아직 풀지 못한 문제**다.

알고리즘 흐름



멈춤 조건이 없다. 분할은 많아야 $N - |\mathcal{P}_0|$번이라 언젠가 끝나고, 그 뒤 구간마다 원 게임 NashConv가 $O(\sqrt{\log k / L_k})$로 줄어든다 (정리 1).

주의: 마지막 분할이 **언제** 일어나는지는 보장하지 못한다. 보장은 그 뒤에만 있다. 실험에서는 판정 문턱 없이 매 구간 끝에 판정했다.

의사코드와 정의

$\mathcal{P} \leftarrow \mathcal{P}_0, \quad L \leftarrow L_0$
for $k = 0, 1, 2, \ldots$
  구간 W_k의 L반복 동안 CFR+로 학습하며
    정보집합마다 $R_I^{W_k} = \sum_{t \in W_k} r_t(I)$를 쌓는다
  for each 정보집합 I:
    $\lambda(I) \leftarrow \arg\max_a R_I^{W_k}(a)$ 또는 없음
  for each bucket B: 라벨이 둘 이상이면
    라벨별 자식으로 나눈다
  $L \leftarrow 2L$
출력: 마지막 구간의 평균 전략 $\bar{\sigma}^{(k)}$

$\mathcal{P}_0$ · (플레이어, 행동집합, 자기 결정 순번)이 같은 정보집합을 하나로

학습기 · bucket마다 RM+(CFR+). 표본이면 외부 샘플링

검정 · 표본 누적값이 잡음보다 클 때만 라벨을 준다 (예: $\tilde{R}(a^*) > z\sqrt{\sum \tilde{r}^2}$). 정확 계산이면 작은 문턱만

출력 정책 · 구간 동안 전략들의 실현 계획 평균 (자기 도달확률로 가중)

원 게임 NashConv를 두 항으로 나눈다

보조정리 1·2 (구간 W의 평균 전략 $\bar{\sigma}^W$, 길이 $L = |W|$)

$$\mathrm{NashConv}(\bar{\sigma}^W) \;\le\; \frac{1}{L}\Big[\sum_B \psi(R_B^W) \;+\; \sum_B H_B^W\Big]$$

bucket 후회 $\psi(R_B)$,
$\psi(x) = \max(0, \max_a x_a)$
bucket이 하나의 정보집합처럼 느끼는 구간 후회

→ **학습기 (RM+)가 $O(\sqrt{t})$로 묶는다**

bucket 안 상쇄 $H_B = \sum_{I\in B}\psi(R_I) - \psi(R_B)$
멤버끼리 방향이 달라 서로 지워진 후회

→ **공통 라벨이면 0, 분할이 0으로 만든다**

라벨 항등식 (보조정리 2):
$H_B = \min_\ell \sum_{I\in B}\big(\psi(R_I) - R_I(\ell)\big)$.
그래서 $H_B = 0 \Leftrightarrow$ 모든 멤버가 함께 최대로 하는 라벨이 있다. 라벨이 같은 bucket에는 상쇄가 남지 않는다.

예시 게임의 B_2 (항상 콜인 한 반복)
$H_{B_2} =$
$\max(0,-1.5)+\max(0,+1.0)-\max(0,-0.5) = 1$
→ 라벨이 갈림 → 나누면 자식마다 0

정리 1: 분할이 끝나면 원 게임 균형으로 수렴한다

정리 1 외부 샘플링 CFR+(동시 갱신), 두 배씩 늘어나는 구간, 문턱 $\theta = o(L)$인 라벨 검정을 쓰면, 확률 $1-\delta$ 이상으로

- 분할은 많아야 $N - |\mathcal{P}_0|$번이다 (모든 표본 경로에서)
- 분할이 없었던 모든 구간 k에서 $\mathrm{NashConv}(\bar{\sigma}^{(k)}) = O\big(\sqrt{\log(kN_A/\delta)/L_k}\big)$
- 따라서 마지막 분할 이후 거의 확실히 $\mathrm{NashConv} \to 0$

증명의 뼈대

1. 분해 (앞 장)
2. bucket 후회: RM+의 구간 상계 + 표본 오차의 시간 균일 집중
3. 상쇄: 라벨이 같으면 문턱 + 표본 오차 이하 (항등식)
4. 분할은 bucket을 쪼개기만 하므로 유한

보장하지 않는 것

- 마지막 분할 시점 (상계 없음)
- 최종 bucket 수 (최악이면 정보집합마다 하나)
- 학습 메모리 (정보집합마다 구간 누적값)
- 압축된 bucket 평균 정책 (보장 대상은 정보집합별 평균)
- 구현의 교대 갱신·선형 평균 (가정 밖)

선행 연구: CFR+IRA와 무엇이 같고 무엇이 다른가

	CFR+IRA (Čermák 외 2020)	**ASWISS 본문 (정리 1)**
보장이 붙은 분할	감시하는 정보집합의 후회가 무후회 속도보다 느리게 줄면 그 정보집합을 떼어 낸다	구간 누적 후회의 라벨이 멤버끼리 갈리면 라벨별로 나눈다
"가장 큰 후회 행동"	**휴리스틱으로 있다**. 논문은 이것만으로는 수렴하지 않는 반례를 보인다	이 기준 자체에 수렴 정리를 붙인다 (라벨 항등식)
학습	매 반복 전체 트리 순회 (정확값)	외부 샘플링 (추정값 + 집중 부등식)
감시 범위	무작위 k_b개 정보집합 (메모리 작음)	모든 정보집합 (메모리 큼)
보장	확률적, $T \geq (\alpha+1)^3$ 부터 $O(T^{-1/3})$, α는 정보집합 수에 지수적	마지막 분할 뒤 $O(\sqrt{\log / L})$, 마지막 분할 시점은 상계 없음

확인이 필요한 점: 라벨 항등식에 따르면 모든 멤버의 최대 후회 행동이 같으면 상쇄는 0이다. 그러니 CFR+IRA의 반례와 정리 1이 둘 다 맞으려면 두 기준의 정의가 달라야 한다 (반복마다의 값인지 구간 누적인지, "없음"과 동률의 처리 등). 원문과 아직 대조하지 못했다.

새롭지 않은 것: 두 배 구간, 분할만 하는 정제, 구간 후회 감시, 최대 후회 행동으로 묶는 착상. 새 주장 후보: 표본 라벨, 라벨 항등식, 이 기준만의 수렴 정리.

실험 설계: 네 가지 질문

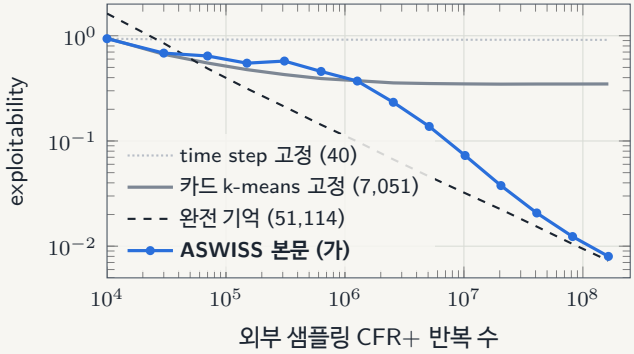
	연구 질문	게임 (크기), 학습기	지표
A	본문 방법이 원 게임 균형에 다가가는가, 고정 추상화보다 얼마나 나은가?	mini-stud (정보집합 51,114), 외부 샘플링 CFR+ 1.6억 반복	exploitability (정확)
B	출발점과 상관없이 분할이 끝나고 균형에 가는가?	Leduc (288), Kuhn (12), 정확한 CFR+ 65.5만 반복	exploitability (정확)
C	다른 라벨 규칙 (부록의 트릭)과 비교하면?	mini-stud 4,096만 반복	exploitability (정확)
D	큰 게임에서는?	7-stud 헤즈업	LBR → 부록 T4

exploitability (정확)
원 게임에서 최선 대응에 잃는 양 (= NashConv / 2). 0이면 균형. 게임 트리 전체를 계산할 수 있는 작은 게임에서만 잴 수 있다.

왜 7-stud는 부록인가
본문 방법은 정보집합 단위인데, 7-stud에서는 정보집합 단위의 라벨과 소속을 정할 수 없다 (앞의 "소속"). 7-stud 실험은 모두 트릭 (원자, bucket 이력)을 썼다.

A. mini-stud: 완전 기억에 다가가고, 고정 추상화는 멈춘다

질문 A · 본문 방법이 원 게임 균형에 다가가는가, 고정 추상화보다 얼마나 나은가?



seed 1 · bucket 평균 정책의 정확한 exploitability (낮을수록 좋음) · 괄호: bucket 수 (고정) · 두 축 모두 로그

1.10배

1.638억 반복: 0.0080 대 완전 기억 0.0073. bucket 26,844개 (정보집합의 53%)

0.348

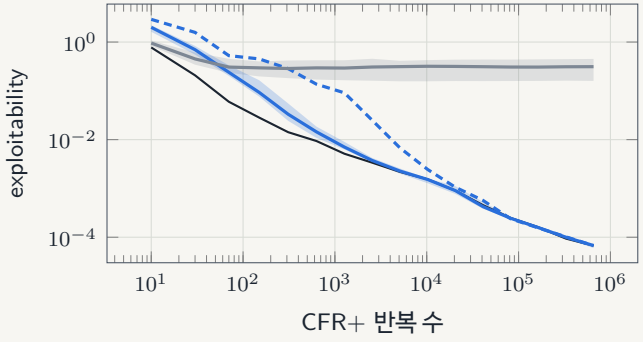
카드 k-means(7,051개)는 처음부터 끝까지 그대로. 본문 방법의 43배 (bucket 수가 달라 같은 조건의 비교는 아니다)

분할은 계속 중

마지막 구간에도 1,186개 bucket이 나뉘었다. 이 학습량에서는 "마지막 분할 이후"에 들어가지 않았다

B. Leduc: 어떤 출발점에서도 분할이 끝나고 균형에 갔다

질문 B · 가장 거친 분할이든 무작위 추상화든, 분할이 끝나고 원 게임 균형에 가는가?



정확한 CFR+ · 정보집합 288 · 띠: 최소–최대 · k-means는 각 실행의 최종 bucket 수에 맞춘 고정 추상화를 같은 반복 수만큼 학습

추상화 없는 CFR+

본문 방법, 무작위 출발 20개 (중앙값)

본문 방법, 가장 거친 $\mathcal{P}_0$ 에서

같은 bucket 수의 k-means (중앙값)

21 / 21 분할 종료

마지막 분할은 모두 16.4만 반복까지 ($\mathcal{P}_0$ 는 4.1만), 그 뒤로 없음

0.0000600–0.0000702

추상화 없는 CFR+는 0.0000673

222–270 / 288

최종 bucket. 같은 수의 k-means 0.160–0.898. Kuhn은 21/21이 12개로 나뉘어 같은 값

C. 라벨 규칙 비교 (mini-stud, 4,096만 반복)

질문 C · 다른 라벨 규칙(부록의 트릭)과 비교하면?

규칙	라벨 단위	라벨 기준	exploitability	bucket	구분
(가) 구간 누적 후회	정보집합	반복 전략들의 후회 합 (표본)	**0.0207**	22,227	본문
방법 A (저장 전략 재생)	정보집합	같은 합을 저장한 전략으로 정확히	0.0265	12,813	트릭 T1
방법 B (평균 전략)	정보집합	분할 시점 평균 전략의 후회 (정확)	0.0197	12,683	트릭 T1
(가) + B	정보집합	둘 중 하나라도 갈리면 나눔	0.0154	26,990	트릭 T1
bucket 이력 + (가)	bucket 이력	(가)를 이력별로 모아서	0.0249	29,916	트릭 T2
bucket 이력 + B	bucket 이력	B를 이력별로 모아서	0.0896	12,895	트릭 T2
완전 기억	–	분할 없음 (정보집합마다 표)	0.0154	51,114	기준
카드 k-means 고정	–	분할 없음	0.348	7,051	기준

seed 1 · bucket 평균 정책의 정확한 exploitability · 마지막 1만 반복 구간 제외 · 라벨마다 잡음의 원천이 다르다 ((가)는 표본, A는 시간 표집, B는 없음) · 1.638억 반복에서는 (가) 0.0080, B 0.0075, (가)+B 0.0071, 완전 기억 0.0073

부록의 트릭: 무엇을 위해 만들었고 근거는 무엇인가

트릭	무엇을 위해	근거와 상태	부록
평균 전략 라벨 (방법 B), 저장 전략 재생 (방법 A)	처음 보는 정보집합의 라벨을 저장한 전략으로 계산, bucket 줄이기	B: 조건부 정리, 학습기 조건 미해결. A: 정리 A로 증명	T1
bucket 이력 키	큰 게임에서 표본을 모으고 소속을 싸게 정하기	이력 안 상쇄로 멈추는 반례 (명제 H4)	T2
역방향 분할	bucket 이력이 못 보는 차이를 앞 bucket을 나눠 드러내기	휴리스틱. 위를 과분할한다 (이력이 정보집합의 99.4–99.8%를 구별)	T3
원자 (카드 군집 × 베팅 요약)	7-stud에서 돌리기	LBR 비교만, seed 1	T4
판정 문턱 ε	학습기 조건 흉내	엄격할수록 나빠졌다	T5
혼합 평균	평균 전략 라벨의 경로 밖 문제	실험만, 증명 없음	T6

공통점: 모두 **큰 게임에서 정보집합 단위를 쓸 수 없는 문제**를 돌아가거나, 평균 전략이라는 다른 기준을 쓰려고 만든 장치다. 본문 정리 1은 이들 없이 성립한다.

검증된 것과 아직 아닌 것

확인된 것

✓ **증명 (초안)** · NashConv 분해와 라벨 항등식, 유한 분할, 정리 1: 외부 샘플링 CFR+로 마지막 분할 뒤 원 게임 균형에 수렴

✓ **Leduc · Kuhn** · 21개 출발점 모두 분할이 끝나고 추상화 없는 CFR+와 같은 값 (Leduc bucket 222–270/288)

✓ **mini-stud** · 1.6억 반복에서 완전 기억의 1.10배, bucket 53%. 고정 k-means는 0.348에 머묾

아직 아닌 것

! **마지막 분할 시점** · 상계 없음. mini-stud는 1.6억 반복에도 분할 중

! **큰 게임** · 정보집합 단위의 라벨·소속 방법이 없다. 7-stud 결과는 모두 트릭

! **메모리** · 정보집합마다 구간 누적값을 둔다

! **가정과 구현** · 정리는 동시 갱신·균등 평균, 구현은 교대 갱신·선형 평균

! **CFR+IRA** · 휴리스틱 반례와의 관계를 원문으로 확인하지 못함. mini-stud는 seed 1개

정리와 다음 단계

학습 중인 전략의 **업데이트 방향**이 한 bucket 안에서 갈리는 곳만 **그 자리에서** 나눈다. 이 규칙만으로 표준 학습기가 원 게임 균형에 수렴한다.

요약

- 라벨 항등식: 라벨이 같은 bucket에는 숨은 손실이 없다
- 정리 1: 분할은 유한하고, 그 뒤 원 게임 균형에 수렴
- 작은 게임: 모든 출발점에서 분할이 끝나고 추상화 없는 CFR+와 같은 값

다음 단계

1. CFR+IRA 원문과 대조 (휴리스틱의 정의와 반례)
2. 큰 게임에서 정보집합 단위의 라벨과 소속 정하기
3. 마지막 분할 시점의 상계 (여유 조건 아래)
4. 학습 메모리 줄이기 (저장 전략 재생의 대가 줄이기)

A1. 기호와 정의 (본문 방법)

반복 t의 반사실 후회 $r_t(I,a) = q_t(I,a) - \sum_b \sigma_t(I,b)\, q_t(I,b)$, $q_t(I,a) = \sum_{h\in I} \pi_{-i}^{\sigma_t}(h) \sum_{z \sqsupseteq ha} \pi^{\sigma_t}(ha,z)\, u_i(z)$

구간 누적 후회 $W = (s,t]$, $L = |W|$: $R_I^W(a) = \sum_{u\in W} r_u(I,a)$, **표본 추정** $\tilde{R}_I^W$ (외부 샘플링, 방문하지 않으면 0)

bucket 합 $R_B^W = \sum_{I\in B} R_I^W$, $\psi(x) = \max(0, \max_a x_a)$

라벨 $\hat{a}_I = \arg\max_a \tilde{R}_I^W(a)$. $\tilde{R}_I^W(\hat{a}_I) > \theta_I^W$이면 $\lambda(I) = \hat{a}_I$, 아니면 $\lambda(I) = \varnothing$ ("없음")

문턱 조건 (T) $0 \le \theta_I^W \le \Delta_I \kappa(W)$, $\kappa(W) = o(|W|)$. 예: 정규 검정 $z\sqrt{\sum \tilde{r}^2} \le z\Delta_I\sqrt{|W|}$

분할 판정 때 멤버 라벨이 두 종류 이상인 bucket을 라벨별로 나눈다. 자식은 $Q = 0$, 평균 표 0에서 시작. 병합 없음

세 양 $C^W = \sum_B \psi(R_B^W)$, $H_B^W = \sum_{I\in B} \psi(R_I^W) - \psi(R_B^W)$, $e_I(\ell) = \psi(R_I^W) - R_I^W(\ell) \ge 0$

학습기 bucket마다 RM+: $Q_{B,t+1} = (Q_{B,t} + \tilde{r}_t(B))^+$, $\sigma_t(B) \propto Q_{B,t}^+$

가정 (S1) 동시 갱신, (S2) $\mathbb{E}[\tilde{r}_t \mid \mathcal{F}_{t-1}] = r_t$, $|\tilde{r}_t(I,a)| \le \Delta_I$, (S3) $\|\tilde{r}_t(B)\|_\infty \le D_B$. 구간은 두 배씩 ($t_{k+1} \le \gamma L_k$, $\gamma = 2$)

출력 $\bar{\sigma}^W$: 구간 동안 lifting된 전략들의 실현 계획 균등 평균 **NashConv** $= \sum_i (\max_{\sigma_i'} u_i(\sigma_i', \sigma_{-i}) - u_i(\sigma))$, exploitability $=$ NashConv$/2$

출처: ASWISS_CONVERGENCE_KO.md §1. $N =$ 정보집합 수, $N_A = \sum_I |A(I)|$, $\Delta_I = I$ 아래 보수의 폭.

A2. 보조정리

보조정리 1 (NashConv 분해) · (S1) 아래 $\mathrm{NashConv}(\bar{\sigma}^W) \le \frac{1}{|W|}\sum_I \psi(R_I^W) = \frac{C^W + H^W}{|W|}$

보조정리 2 (라벨 항등식) · $H_B^W = \min_{\ell \in A_B \cup \{\varnothing\}} \sum_{I \in B} e_I(\ell)$. 그래서 $H_B = 0 \Leftrightarrow$ 모든 멤버가 함께 최대로 하는 라벨이 있다

보조정리 3 (RM+ 구간 상계) · B가 τ_B에 생기고 $W = (s, t]$, $s \ge \tau_B$이면 $\psi(\tilde{R}_B^W) \le \|Q_{B,t}\|_\infty \le D_B\sqrt{|A_B|\,t}$ (표본이어도 확률 없이 성립)

보조정리 4 (시간 균일 집중) · $\varepsilon_I(t) = 4\Delta_I\sqrt{t \ln\left(\pi^2 N_A (1+\log_2 t)^2/(3\delta)\right)}$. 확률 $1-\delta$ 이상으로 모든 구간에서 $\|R_I^W - \tilde{R}_I^W\|_\infty \le 2\varepsilon_I(t)$

보조정리 5 (라벨이 같은 bucket) · 위 사건에서 B의 모든 멤버가 같은 라벨이면 $H_B^W \le \sum_{I \in B}\left(\theta_I^W + 4\varepsilon_I(t)\right)$

보조정리 6 (분할 유한성) · 분할마다 bucket 수가 엄격히 늘므로 분할은 모든 표본 경로에서 많아야 $N - |\mathcal{P}_0|$번

출처: ASWISS_CONVERGENCE_KO.md §2. 상태: 모두 [증명], 보조정리 2·3·5는 수치 확인도 했다. 검토 전 초안.

A3. 정리 1의 정확한 진술과 따름 결과

정리 1 · (S1)–(S3), (T), 두 배 구간을 가정한다. 확률 $1-\delta$ 이상으로, 끝에서 분할이 없었던 모든 구간 k에서

$$\mathrm{NashConv}(\bar{\sigma}^{(k)}) \le \frac{1}{L_k}\Big[\sum_{B\in\mathcal{P}_k} D_B\sqrt{|A_B|\,t_{k+1}} + \sum_I \big(\theta_I^{(k)} + 6\varepsilon_I(t_{k+1})\big)\Big] = O\Big(\sqrt{\tfrac{\log(kN_A/\delta)}{L_k}}\Big).$$

마지막 분할 구간 $k^* < \infty$ 이후 모든 구간에 적용되고, 거의 확실히 $\mathrm{NashConv}(\bar{\sigma}^{(k)}) \to 0$이다.

따름정리 3.1 (실행 전체의 평균) · $T = t_{K+1}$에서 $\mathrm{NashConv}(\bar{\sigma}^{(0,T]}) = O\big(t_{k^*+1}/T + \sqrt{\log/T}\big)$

명제 3.2 (분할 중인 구간) · 분할된 bucket이 있는 구간의 상계는 아직 라벨이 갈리는 bucket들의 "소수파 후회" $\min_\ell \sum_I e_I(\ell)$가 좌우한다

비고 3.3 (속도) · $\sum_B D_B \le \sum_I \Delta_I$이므로, k^* 이후의 차수는 완전 기억 CFR+의 상계 $\sum_I \Delta_I\sqrt{|A|/T}$와 로그 인자를 빼면 같다

비고 3.4 (자식 표 상속) · 자식이 부모의 Q를 물려받아도 $\|Q_{\text{자식}}\|_2 \le \|Q_{\text{부모}}\|_2$이면 같은 차수

출처: ASWISS_CONVERGENCE_KO.md §3. 마지막 분할 시점 k^*의 상계는 없다 (§7.1).

A4. 정리 1이 보장하지 않는 것

1. **마지막 분할 시점에 상계가 없다.** CFR+IRA도 이를 직접 구하지 못했다(원문의 T_{lim}은 정보집합 수에 지수적). 후보: 상위 두 행동의 누적 후회 차가 $\Omega(L)$인 여유 조건
2. **최종 bucket 수에 보장이 없다.** 고정 수준의 z 검정은 거짓 라벨이 무한히 자주 나올 수 있어 원리적으로 정보집합마다 하나까지 갈 수 있다(수렴은 유지). 여유 라벨 집합(A5)은 좋은 사건 위에서 거짓 분할을 없앤다
3. **학습 메모리를 줄이지 않는다.** 정보집합마다 구간 누적값($|\mathcal{I}| \cdot |A|$)을 둔다. 저장 전략 재생(방법 A)은 이를 bucket 표 K개로 바꾸는 대신 속도를 잃는다
4. **보장 대상은 정보집합별 평균이다.** bucket 표에 압축한 평균에는 보장이 없다(mini-stud의 한 실행에서는 가까웠다: 0.0216 대 0.0198)
5. **가정과 구현이 다르다.** 정리는 동시 갱신과 구간 균등 평균, 구현은 교대 갱신과 선형 평균
6. **충분조건일 뿐이다.** 최선 응답이 가지 않는 정보집합의 후회도 상쇄를 키워 불필요한 분할을 낳을 수 있다(정확성 손해는 없고 효율 손해만)

출처: ASWISS_CONVERGENCE_KO.md §7.1–7.2.

A5. 잡음 아래의 라벨: 여유 라벨 집합과 저장 전략 재생

보조정리 9 (여유 라벨 집합) · 추정치가 $\|\hat{x}_I - x_I\|_\infty \le \eta_I$이면, $\hat{M}(I) = \{\ell : \hat{x}_I(\ell) \ge \max \hat{x}_I - 2\eta_I\}$로 판정할 때

- 참 최대 라벨은 늘 $\hat{M}(I)$에 들어 있고, 참으로 일치하는 bucket은 나뉘지 않는다 (거짓 분할 없음)
- 나뉠 때 각 멤버가 가는 자식의 손실은 $4\eta_I$ 이내다

정리 A (저장 전략 재생) · 구간마다 무작위 시점 K_k개의 bucket 전략을 저장해 두고, 구간 끝에 전체 트리에서 정확히 다시 계산해 $\hat{R}_I = \frac{L_k}{K_k}\sum_j r_{\tau_j}(I)$로 라벨을 매긴다. 그러면 정리 1과 같은 꼴의 상계에 $4\sum_I \Delta_I \sqrt{(2/K_k)\ln(\pi^2 N_A (k+1)^2/3\delta)}$가 더해진다.

- 학습 중 정보집합별 누적값이 필요 없고, 방문하지 않은 정보집합에도 라벨이 붙는다
- 대가: 재생에 전체 트리 순회가 필요하고(작은 게임만), K_k가 작으면 속도가 느려진다

출처: ASWISS_CONVERGENCE_KO.md §9.2–9.3. mini-stud 실험의 (가)는 정규 $z = 2$ 검정을 썼다. 여유 라벨 집합을 표본값에 쓰면 탐지력이 크게 떨어졌다 (0.200, bucket 5,284).

A6. 실험 설정과 비교 조건의 차이

	mini-stud	Kuhn · Leduc
게임	정보집합 51,114	Kuhn 12, Leduc 288 (rank만)
학습기	외부 샘플링 CFR+(교대 갱신, 선형 평균)	정확한 전체 트리 CFR+
학습량	1.638억 반복 (규칙 비교는 4,096만)	65만 5,350반복
구간	1만 반복에서 두 배씩, 자식은 표를 0에서	10반복에서 두 배씩
라벨	정규 검정 $z = 2$	도달 확률당 후회가 10^{-3} 보다 클 때
출발점 · seed	time step 40개 bucket, seed 1	$\mathcal{P}_0$ + 무작위 추상화 20개 (트리 10, 자유 10)
지표	bucket 평균 정책의 정확한 exploitability	같음
기준선	완전 기억, 카드 k-means 7,051 (bucket 수 다름), time step 고정	추상화 없음, 실행마다 최종 bucket 수에 맞춘 k-means

출처: aswiss/README_KO.md, aswiss/small/README_KO.md, small/run_leduc_infoset.sh. mini-stud 비교군의 최종 bucket 수가 서로 다르다 (본문 26,844, B 14,910, k-means 7,051). seed가 하나라 mini-stud의 작은 차이는 같은 값으로 읽는 것이 맞다.

T1. 평균 전략 라벨 (방법 B)

정의 · 판정 시점의 평균 전략 $\bar{\sigma}$을 고정하고, 그 한 프로필 아래의 순간 반사실 후회 $r^{\bar{\sigma}}(I)$로 라벨을 매긴다. 저장한 $\bar{\sigma}$ 하나로 처음 보는 정보집합의 라벨도 계산할 수 있다.

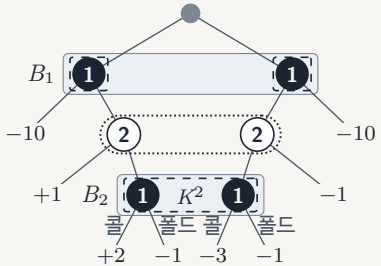
이론 (조건부) · 모든 bucket이 일치하면 $\mathrm{NashConv}(\bar{\sigma}) \le \rho_{\mathcal{P}}(\bar{\sigma})$ (정리 B1). 학습기가 경로 밖까지 $\rho_{\mathcal{P}} \le \varepsilon$인 프로필을 주면 유한 라운드에 $\mathrm{NashConv} \le \varepsilon$ (정리 B3). 표준 CFR 평균은 이 조건을 만족하지 않는다 (명제 B4, 추상화 없는 Leduc도 $\rho/2$가 0.0855에서 멈춤)

실험

- mini-stud 4,096만: 0.0197 (bucket 12,683), 본문 (가)는 0.0207 (22,227). 1.638억: 0.0075 (14,910, 완전 기억의 1.03배)
- (가)와 함께 쓰면 1.638억에서 0.0071 (28,747)
- 인증값 $\rho/2$는 실제의 5.6배였다. 조건은 성립하지 않았는데 분할은 좋았다
- Leduc 정보집합 단위: 중앙값 0.0000670으로 (가)와 같았지만, $\mathcal{P}_0$ 출발은 65.5만 반복에도 분할이 이어져 0.0000999

출처: ASWISS_CONVERGENCE_KO.md §9, aswiss/README_KO.md. B의 라벨은 정확값이고 (가)는 표본이라 잡음 조건이 다르다.

T2. bucket 이력 키와 이력 안 상쇄 (명제 H4)



파선: bucket 이력. B_2에는 이력이 하나뿐

bucket 이력 · (지나온 bucket 번호, 둔 행동, 새 관측). 큰 게임에서 같은 키의 정보집합끼리 표본을 모으고, 소속을 번호 조회로 정하려고 만든 키

문제 (명제 H4) · 결정 2의 H와 L은 키가 같다 (B_1, 체크, 상대 베팅). 라벨을 키 단위로 모으면 폴드의 후회가 $-1.5 + 1.0 = -0.5$로 상쇄되어 라벨이 "콜", 나눌 것이 없다 → **NashConv 1에서 멈춘다**

실험 · mini-stud에서 bucket 이력 + B는 0.0896 (정보집합 단위 B는 0.0197). 정보집합 기준 상쇄가 1.20으로 컸다

본문 방법은 라벨을 정보집합 단위로 매기므로 이 상쇄가 없다. 이 문제는 키를 bucket 이력으로 거칠게 잡았기 때문에 생긴다.

T3. 역방향 분할 (휴리스틱)

규칙 · 같은 bucket 이력 안의 정보집합끼리 라벨이 갈리면, 두 정보집합의 과거를 거슬러 올라가 이력은 달랐는데 같은 bucket에 들어간 앞 결정(보조정리 H3의 "합쳐진 지점")을 찾아 **그 앞 bucket을** 나눈다. 그러면 뒤 결정의 키가 갈라진다.

성격 · 아래 bucket의 문제를 풀려고 위 bucket을 과분할한다. 학습기 조건 아래에서는 정지 시 NashConv $\leq \varepsilon$ (정리 H5, 조건부)

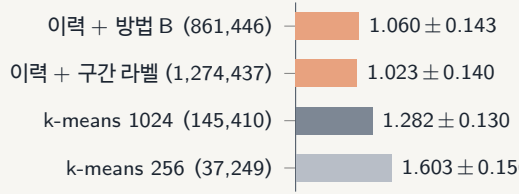
실험

- mini-stud (bucket 이력 + B, seed 3개): 0.0929 → 0.0277. 그 대가로 bucket 이력이 정보집합의 **99.4–99.8%**를 구별했다 (사실상 정보집합 단위로 돌아감)
- Leduc (bucket 이력 + B, 21개 출발점): 모두 정지 상태, 0.000067. 정방향만 쓰고 트리를 유지하면 $\mathcal{P}_0$에서 2.93에 멈췄다
- 트리 구조(부모 bucket 하나 = 추상화의 완전 기억)는 CFR+가 추상 게임을 풀게 했지만(D/2 0.00008 대 0.26) 원 게임 exploitability는 낫지 않았다 (1.81 대 1.74)
- 7-stud 5.11M: 역방향 효과 -0.23 ± 0.21 (LBR)

출처: ASWISS_HISTORY_PROOF_KO.md §4·§8, aswiss/README_KO.md, aswiss/small/README_KO.md, aswiss/stud7/README_KO.md.

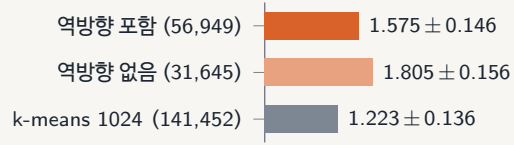
T4. 7-stud (원자와 bucket 이력을 쓴 실행)

100M roots · 역방향 없음



방법 B − k-means 1024 = -0.22 $[-0.41, -0.04]$
(같은 deal로 짝지은 차이)

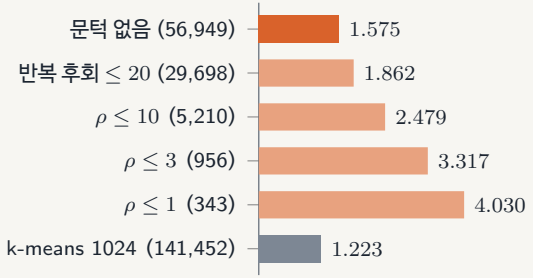
5.11M roots · 역방향 포함 시범



역방향 효과 -0.23 ± 0.21. k-means 1024보다 아직 $+0.35 \pm 0.19$ 높다

평균 정책 LBR (낮을수록 좋음, ± 95% 구간) · 괄호: bucket 수 · **LBR은 exploitability의 근사 하한** · PolicyLBR 64 particles, 20,000 pair, seed 1 · 헤즈업, 5구부터 학습, 4구 버림·공개 휴리스틱 · 라벨 단위는 정보집합이 아니라 원자·bucket 이력 · **두 패널은 학습량·bucket 수·버전이 달라 서로 비교하지 않는다**

T5. 판정 문턱 ε (학습기 조건 흉내)



7-stud 5.11M roots (bucket 이력 + B + 역방향) · 평균 정책 LBR, 20,000 pair · 괄호: 마지막 bucket 수

엄격할수록 나빴다 · 기다리는 동안 bucket이 수십–수백 개에 묶여 있었다

후회가 작다 $\neq$ 정책이 좋다 · $\varepsilon = 1$은 bucket 36개, $\rho = 0.86$에서 통과했지만 LBR 7.5 (같은 시점 k-means의 7.6배)

mini-stud · $\varepsilon = 0.2$에서 정지 상태가 나왔고 실제 0.034–0.038 $\leq$ 인증 0.19–0.20. $\varepsilon/\sqrt{t}$ 문턱은 추상화를 얼렸다

본문과의 관계 · 정리 1은 문턱 없이 매 구간 판정한다

T6. 혼합 평균 (평균 전략 라벨의 경로 밖 문제)

문제 · 평균 전략은 자기가 거의 가지 않게 된 곳에서 초반 값에 멈춘다. 정책에는 영향이 없지만 (실현 계획의 질량이 0), 자주 가는 정보집합의 라벨이 그 아래의 멈춘 값으로 계산되어 분할 신호를 놓친다.

규칙 (`--avg-fill plain`) · 판정에 쓰는 전략만 바꾼다. 평균 전략으로 자기 도달확률이 10^{-4} 이상인 곳은 평균 전략, 그보다 작은 곳은 그 bucket의 현재 전략들의 단순 평균. 내놓는 정책은 그대로다.

결과 · 명제 B4(a) 반례: 평균 전략만으로는 끝까지 안 나뉘었고 (NashConv 1), 혼합 평균으로는 150 반복에 나뉘어 0으로 수렴. Leduc 21개 출발점: 정책과 bucket 수는 그대로, 판정에 쓴 평균의 $\rho_{\mathcal{P}}/2$ 가 0.090 $\rightarrow$ 0.00029. mini-stud: 차이 없음 (0.0277 $\rightarrow$ 0.0271).

한계 · 증명 없음. 문턱 10^{-4} 한 값만 시험. 7-stud 100M 비교 (hist_bbf 대 hist_bb) 는 진행 중.

출처: aswiss/AVG_FILL_KO.md. 본문 방법 ((가)) 은 반복 전략들의 후회를 쓰므로 이 문제가 없다.